

Optimización biomecánica del ciclismo asistida por inteligencia artificial

Ing. Rodrigo Iván Goñi

Carrera de Especialización en Inteligencia Artificial

Director: MSc. Fernando Corteggiano

Jurados:

PhD. David Deyong
Jurado 2 (pertenencia)
Jurado 3 (pertenencia)

Resumen

En la presente memoria se describe el desarrollo de un sistema inteligente y personalizado para la optimización de parámetros biomecánicos de una bicicleta. Este trabajo pretende maximizar la eficiencia del pedaleo y minimizar el riesgo de lesiones, con el fin de democratizar el acceso a una biomecánica de precisión con un bajo costo. Para su implementación fueron esenciales los conocimientos en detección de pose por redes neuronales, análisis cinemático y algoritmos de optimización multiobjetivo.

Agradecimientos

Esta sección es para agradecimientos personales y es totalmente **OPCIONAL**.

Índice general

Resumen	I
1. Introducción general	1
1.1. Contexto y problemática	1
1.2. Estado del arte	2
1.2.1. El estándar cinematográfico: captura de movimiento 3D y 4D	2
1.2.2. Cuantificación de la interfaz: mapeo avanzado de presión	3
1.2.3. El imperativo aerodinámico y la democratización del análisis	4
1.2.4. Síntesis y limitaciones del estado del arte	4
1.3. Motivación y propósito	5
1.4. Objetivos y alcance	5
2. Introducción específica	7
2.1. Metodología	7
2.2. Marco teórico	8
2.2.1. Visión artificial para estimación de pose	8
2.2.2. Algoritmos genéticos	9
2.3. Algoritmos de optimización	10
2.4. Métricas de evaluación	11
2.4.1. Métricas objetivas	11
2.4.2. Métricas subjetivas	12
3. Diseño e implementación	13
3.1. Análisis del software	13
4. Ensayos y resultados	15
4.1. Pruebas funcionales del hardware	15
5. Conclusiones	17
5.1. Conclusiones generales	17
5.2. Próximos pasos	17
Bibliografía	19

Índice de figuras

1.1. Ilustración de la problemática de un mal ajuste biomecánico.	1
1.2. Ejemplo de un sistema profesional de análisis biomecánico en laboratorio.	2
2.1. Diagrama de flujo de la metodología CRISP-DM adaptada para el trabajo.	8
2.2. Frontera de Pareto tridimensional con los tres objetivos a minimizar: coeficiente aerodinámico (CdA), frecuencia cardíaca y riesgo de lesión.	11

Índice de tablas

2.1. Tabla comparativa de modelos de estimación de pose.	9
2.2. Tabla de definición de métricas de evaluación.	12

Dedicado a... [OPCIONAL]

Capítulo 1

Introducción general

Este capítulo presenta una introducción general al trabajo. Primero, se expone el contexto y la problemática de la biomecánica en el ciclismo. A continuación, se analiza el estado del arte de las soluciones de ajuste, o *bike fitting*, y sus limitaciones actuales. Se detalla la motivación y el propósito que impulsan el desarrollo de una nueva solución. Finalmente, se definen los objetivos específicos y el alcance del prototipo propuesto.

1.1. Contexto y problemática

La biomecánica en el ciclismo es un factor fundamental para mejorar el rendimiento y prevenir lesiones [1]. Su principio se basa en la adaptación de la bicicleta a las características físicas del ciclista. Un ajuste incorrecto no solo puede causar lesiones, sino también una disminución en la potencia de salida que puede alcanzar hasta un 20 % [2]. En la figura 1.1 se ilustra esta problemática.

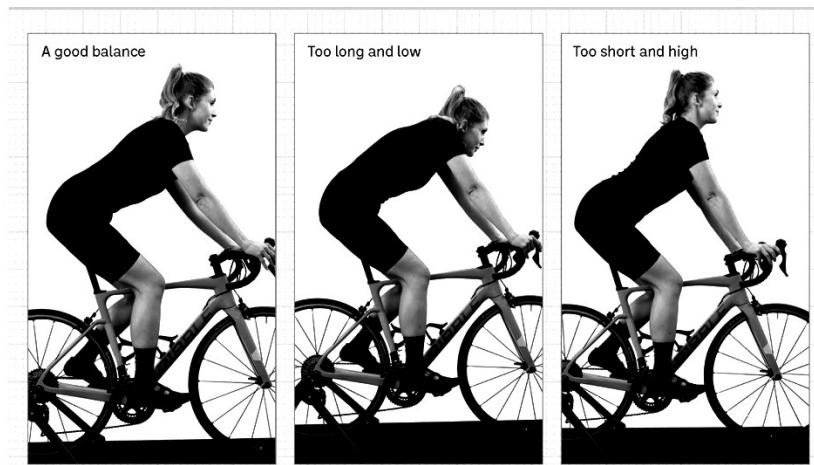


FIGURA 1.1. Ilustración de la problemática de un mal ajuste biomecánico.

Sin embargo, el acceso a un análisis biomecánico profesional presenta barreras significativas. Las soluciones actuales suelen ser costosas, tienen baja disponibilidad y exigen visitas a laboratorios especializados [3].

1.2. Estado del arte

El *bike fitting*, o ajuste biomecánico de la bicicleta, ha transitado desde un proceso artesanal basado en la goniometría estática y la experiencia subjetiva, hacia una ciencia de datos multimodal y de alta precisión [4]. Las soluciones convencionales, basadas en un análisis estático y puntual, dependen en gran medida de la experiencia del biomecánico. La recomendación de repetir el ajuste anualmente, sumada al alto costo y la escasa disponibilidad, provoca que la mayoría de los ciclistas no mantengan una configuración óptima.

Los sistemas profesionales de laboratorio, como el que se observa en la figura 1.2, ejemplifican este enfoque. El estado del arte actual ya no se define por una única tecnología, sino por la convergencia e integración de múltiples flujos de datos. Este análisis sintetiza el panorama de las soluciones de vanguardia, que se pueden agrupar en cuatro pilares tecnológicos principales que definen la práctica avanzada.



FIGURA 1.2. Ejemplo de un sistema profesional de análisis biomecánico en laboratorio.

1.2.1. El estándar cinemático: captura de movimiento 3D y 4D

La evolución fundamental en el *bike fitting* ha sido el paso de las mediciones estáticas a las dinámicas. Los métodos tradicionales, que emplean goniómetros manuales o análisis de vídeo en 2D con el ciclista detenido, han demostrado ser insuficientes [4]. Estos métodos no logran capturar la biomecánica real del ciclista bajo carga, es decir, mientras pedalea activamente [5].

El ajuste dinámico tridimensional (3D) se considera el estándar que ofrece las mayores garantías. Sistemas como Retül o Vicon [5, 6] se han establecido como referentes y utilizan múltiples cámaras infrarrojas para rastrear marcadores en puntos anatómicos clave en tiempo real. Esto permite un análisis preciso del movimiento en los tres planos del espacio (sagital, frontal, transversal), lo que proporciona una imagen completa de la cinemática del ciclista que es imposible de obtener con métodos más simples [5].

La superioridad del 3D no es meramente cualitativa, ha sido cuantificada rigurosamente. Un estudio fundamental de Fonda, Sarabon y Li [7] comparó directamente los métodos cinemáticos. El hallazgo clave fue que, en comparación con el estándar 3D, el análisis 2D subestima de forma estadísticamente significativa el ángulo de la articulación de la rodilla. Esta subestimación sistemática es un error inherente a la proyección de un movimiento tridimensional en un plano bidimensional. El estudio determinó la necesidad de añadir un factor de corrección específico de $2,2^\circ$ al valor 2D para aproximar el valor real 3D [7]. Esto subraya la imprecisión inherente de los métodos 2D para una verdadera optimización biomecánica.

El estado del arte ha avanzado más allá de la simple dicotomía estático vs. dinámico. El análisis no solo debe ser dinámico, sino también funcional, es decir, realizado bajo cargas de trabajo (potencia) relevantes. Una revisión sistemática de 2019 [1] sobre la biomecánica del ciclismo proporciona una visión crítica: la cinemática del ciclista se ve influenciada significativamente por la carga de trabajo. A medida que aumenta la potencia, los ciclistas exhiben cinemáticas compensatorias para mantener la producción de fuerza. Por lo tanto, un ajuste realizado a baja intensidad puede ser biomecánicamente inválido o subóptimo para las condiciones de competición del ciclista. La revisión establece rangos óptimos para el Ángulo de Flexión de Rodilla (KFA) medido dinámicamente, que se reduce de $33\text{--}43^\circ$ a baja intensidad, a un rango de $30\text{--}40^\circ$ a alta intensidad [1].

1.2.2. Cuantificación de la interfaz: mapeo avanzado de presión

Si bien la cinemática 3D describe cómo se mueve el cuerpo del ciclista en el espacio, no puede describir cómo el ciclista interactúa con la bicicleta. El mapeo avanzado de presión [8] es la tecnología de vanguardia diseñada para cuantificar la estabilidad y la distribución de la fuerza en los tres puntos de contacto principales: sillín, pies y manillar.

Empresas como Gebiomized[9] lideran este dominio con alfombrillas de sensores flexibles y de alta resolución que proporcionan información previamente inaccesible. La aplicación más crítica es el análisis del sillín. Más allá de la simple comodidad subjetiva, el sistema mide la distribución de la presión (media y máxima) y las asimetrías izquierda/derecha. Sin embargo, la métrica más importante generada es el Centro de Movimiento y el Patrón de Rastreo Pélvico (*Pelvic Tracking*). El sistema mapea cómo se mueve el centro de presión del ciclista sobre el sillín mientras pedalea [9].

Esta tecnología proporciona el vínculo causal crucial entre la cinemática y la estabilidad de la interfaz. A menudo, un movimiento cinemático aberrante de la rodilla (detectado por un sistema 3D) no es un problema de la rodilla en sí. Es un síntoma. La causa raíz suele ser la inestabilidad pélvica. La tecnología de mapeo de presión es la única herramienta que puede diagnosticar y cuantificar objetivamente esta inestabilidad pélvica. De manera similar, esta tecnología se aplica a las plantillas (para analizar la transferencia de potencia y estabilizar el pie como una palanca rígida [10]) y al cockpit (para mitigar la fatiga y las neuropatías en las extremidades superiores) [9].

1.2.3. El imperativo aerodinámico y la democratización del análisis

Para el ciclismo de rendimiento, la biomecánica es solo la mitad de la ecuación. Existe un conflicto central: la posición más aerodinámica (típicamente más baja y estrecha) a menudo restringe la biomecánica de la producción de potencia y compromete el confort [10]. El estado del arte busca cuantificar y optimizar este equilibrio.

Históricamente, esto requería costosas pruebas en túneles de viento físicos [11]. La primera evolución fue la Dinámica de Fluidos Computacional (CFD) [12, 13]. Las soluciones más recientes integran CFD con Inteligencia Artificial (IA). Plataformas emergentes como AiRO[14] se describen como el primer sistema de *bike-fit* modelado por CFD e impulsado por IA. El sistema genera un modelo 3D del ciclista y ejecuta un análisis CFD en la nube para calcular la resistencia aerodinámica (CdA) en minutos [14]. Un enfoque alternativo o complementario son los sensores aerodinámicos portátiles en tiempo real, como el Notio Aerometer. Este dispositivo utiliza un tubo de Pitot, GPS y una conexión a un medidor de potencia para calcular el CdA de referencia del ciclista en condiciones del mundo real [15, 16].

Paralelamente a estos sistemas de alta especialización, ha surgido una tendencia de democratización del *bikefitting* mediante aplicaciones de *smartphone*. Plataformas como MyVeloFit [17] y Bike Fast Fit [18] ofrecen análisis biomecánicos por una fracción del costo de un *fit* de laboratorio. Su innovación más significativa (particularmente MyVeloFit) es la integración de evaluaciones de movilidad funcional [19]. El proceso comienza con el usuario que realiza una serie de evaluaciones de movilidad. La IA personaliza la ventana de ajuste objetivo basándose en los resultados de la flexibilidad individual del usuario [17].

Esto, sin embargo, presenta un conflicto académico fundamental. En esencia, estas aplicaciones siguen siendo sistemas de cinemática 2D. Esto las pone en contradicción directa con los hallazgos (como los de Fonda et al. [7]) que establecieron que el 2D subestima sistemáticamente los ángulos clave. La pregunta crítica que sigue siendo un área clave para la investigación futura, es si los algoritmos de IA pueden compensar adecuadamente los errores inherentes de perspectiva y paralelo de una captura 2D.

1.2.4. Síntesis y limitaciones del estado del arte

El análisis del estado del arte revela una clara trayectoria: una evolución desde la medición de ángulos estáticos hacia la creación de un perfil dinámico y multimodal del sistema ciclista-bicicleta. El ajuste óptimo ya no es un conjunto estático de coordenadas, sino un equilibrio dinámico validado a través de múltiples capas de datos.

El desafío principal en este campo es encontrar el balance óptimo entre la posición que maximiza la velocidad y aquella que minimiza el esfuerzo y el riesgo de lesiones. Frecuentemente, la postura más aerodinámica no es la más sostenible a largo plazo. El papel del profesional ha pasado de ser un técnico a ser un integrador de datos, que debe sopesar métricas a menudo contradictorias.

Las limitaciones de las soluciones de vanguardia (sistemas 3D, mapeo de presión, CFD) son su alto costo y su dependencia de un entorno de laboratorio. Esto define el enfoque de las soluciones tradicionales: un análisis estático y puntual.

Esta aproximación ha impedido una verdadera optimización biomecánica continua para el ciclista, lo que define la problemática central que motiva el presente trabajo.

1.3. Motivación y propósito

La motivación de este trabajo surge de la necesidad de superar las limitaciones del estado del arte, detalladas en la sección 1.2. El alto costo, la baja disponibilidad y el enfoque estático de las soluciones tradicionales han impedido una verdadera optimización biomecánica continua para el ciclista.

En este contexto, se reconoce que el ajuste debe ser un proceso dinámico [4, 7]. La necesidad de un ajuste frecuente obedece a que la práctica constante del deporte genera adaptaciones fisiológicas en el ciclista. Estas adaptaciones incluyen una mejora en la capacidad de elongación y flexibilidad muscular, lo que modifica los rangos de movimiento óptimos para el pedaleo. Por consiguiente, la configuración ideal de la bicicleta evoluciona con el progreso físico del deportista y exige una reevaluación periódica.

El valor fundamental de la solución propuesta radica en la capacidad de ofrecer al ciclista la realización de ajustes frecuentes y a un costo significativamente menor que las alternativas tradicionales. Esta aproximación permite una mejora continua del rendimiento y una gestión activa de la prevención de lesiones al considerar la evolución de las capacidades físicas del deportista.

El propósito de este trabajo es desarrollar un sistema inteligente y personalizado que enfrente el desafío de la optimización multiobjetivo. El sistema integra la detección de pose mediante redes neuronales y el análisis exhaustivo de datos provenientes de sensores de ciclismo. Se buscó optimizar de forma integral los parámetros biomecánicos de la bicicleta. En esencia, se persiguió maximizar la potencia y eficiencia del pedaleo, minimizar el riesgo de lesiones, y equilibrar estos factores con la aerodinámica para alcanzar la máxima velocidad posible.

1.4. Objetivos y alcance

El objetivo principal de este trabajo fue desarrollar un prototipo de un sistema inteligente que optimice los parámetros biomecánicos de la bicicleta. Se buscó maximizar la potencia y eficiencia del pedaleo, minimizar el riesgo de lesiones y equilibrar estos factores con la aerodinámica.

El alcance del trabajo incluyó:

- El desarrollo de un sistema de optimización personalizado que proporciona recomendaciones para el ajuste biomecánico de la bicicleta.
- Un ciclo continuo de análisis y retroalimentación que incluye la captura de datos (video y sensores), el análisis de movimiento mediante estimación de pose 2D, y un modelo biomecánico.
- Un algoritmo de optimización integral para lograr el equilibrio entre ajuste biomecánico, aerodinámica y prevención de lesiones.
- La generación de un reporte con recomendaciones claras para que el usuario pueda ajustar la bicicleta.

El presente trabajo no incluyó:

- El desarrollo de hardware personalizado para la captura de datos. Se utiliza la integración con sensores comerciales existentes.
- El entrenamiento de la red neuronal de detección de pose desde cero. Se espera utilizar o adaptar redes neuronales preexistentes.
- La simulación de factores externos complejos, como condiciones climáticas extremas.

Capítulo 2

Introducción específica

En este capítulo se presenta el marco metodológico y teórico que sustentó el desarrollo del trabajo. Se detallan las fases del modelo de gestión adaptado, las tecnologías de *software* seleccionadas para el análisis y la optimización, y las métricas definidas para la validación del sistema. El contenido de este capítulo se basa en la planificación y los conceptos establecidos en el documento de gestión del proyecto [20].

2.1. Metodología

Para la gestión y ejecución de este trabajo, se adaptó la metodología CRISP-DM (*Cross-Industry Standard Process for Data Mining*). Esta adaptación fue necesaria para alinear las fases estándar de un proyecto de minería de datos con los objetivos específicos de un proyecto de optimización biomecánica asistida por inteligencia artificial, como se describe en la sección 8 del documento de planificación [20].

El modelo se reestructuró en las siguientes fases principales, ajustadas al contexto del trabajo:

- Comprensión del negocio y del problema biomecánico.
- Comprensión y adquisición de los datos (video, sensores de rendimiento y datos antropométricos).
- Preparación y preprocesamiento de los datos, incluyendo la extracción de pose y el filtrado de señales.
- Modelado y simulación biomecánica y aerodinámica.
- Evaluación de las soluciones generadas por el optimizador (análisis del frente de Pareto).
- Despliegue, materializado en la generación del reporte de recomendaciones para el ciclista.

La figura 2.1 muestra el diagrama de flujo de la metodología implementada.

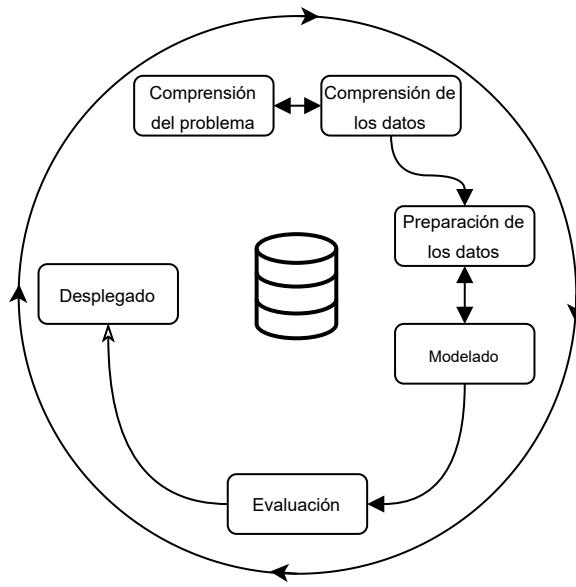


FIGURA 2.1. Diagrama de flujo de la metodología CRISP-DM adaptada para el trabajo.

2.2. Marco teórico

El desarrollo del sistema se fundamentó en dos pilares tecnológicos principales: la visión artificial para el análisis cinemático y los algoritmos genéticos para la optimización.

2.2.1. Visión artificial para estimación de pose

Para la extracción de las coordenadas 2D de los puntos clave del ciclista desde la captura de video, se realizó un análisis de las herramientas de estimación de pose (*pose estimation*) disponibles. Se evaluaron modelos preentrenados como Keypoint R-CNN y MediaPipe, mencionados en la planificación del proyecto [20].

Estos modelos utilizan redes neuronales convolucionales profundas (CNN) para identificar y localizar articulaciones humanas clave (ej. codos, rodillas, tobillos) en cada fotograma. Las CNN se han convertido en el estándar en tareas de visión por computador, con un diseño inspirado en el córtex visual humano. Su principio fundamental es la abstracción jerárquica de características [21]. Las capas iniciales detectan rasgos de bajo nivel como bordes y texturas, que se componen en representaciones más complejas en capas sucesivas.

El paradigma dominante actual para esta tarea no es la regresión directa de coordenadas, la cual demostró ser difícil, particularmente ante oclusiones [22]. En su lugar, el problema se reformula como la detección basada en mapas de calor (*heatmaps*) [23]. En este enfoque, la CNN genera un conjunto de mapas de calor 2D, uno por cada articulación [24]. Cada mapa de calor funciona como una distribución de probabilidad espacial, donde el valor de cada píxel representa la confianza de que la articulación se ubique allí. Este método permite codificar la

incertidumbre: una articulación visible genera un pico de alta confianza, mientras que una articulación oculta se representa por un pico más difuso y bajo.

Finalmente, se seleccionó el modelo *MediaPipe BlazePose*. Esta decisión no se basó únicamente en la precisión, sino en dos justificaciones de dominio específicas. Primero, su alineación con la tarea: BlazePose es un rastreador (*tracker*) optimizado para la coherencia temporal en vídeo [25], a diferencia de los modelos que detectan en cada fotograma. Segundo, su alineación con el dominio biomecánico: el modelo predice una topología de 33 *landmarks* 3D [26] que incluye puntos clave en pies y talones, elementos indispensables para el análisis biomecánico del ciclismo que no están presentes en las 17 articulaciones de los modelos COCO [27].

En la tabla 2.1 se presenta una comparativa de los modelos evaluados.

TABLA 2.1. Tabla comparativa de modelos de estimación de pose.

Modelo	Precisión (mAP)	Velocidad (FPS)	Observaciones
MediaPipe Blaze-Pose	62.6 - 68.1 (en 17 kpts) [28]	~30 FPS (CPU Laptop) [25]	Optimizado para <i>tracking</i> en video. Topología de 33 <i>landmarks</i> 3D [26].
Keypoint R-CNN CO-CO [29]	64.0 (kp. AP en CO-CO) [29]	~13.8 FPS (GPU V100) [29]	Alta precisión. Costo escala linealmente con Nro. de personas [25].

2.2.2. Algoritmos genéticos

Los algoritmos genéticos (AG, *Genetic Algorithms*) son metaheurísticas de búsqueda inspiradas en el proceso de selección natural [30, p. 19]. Pertencen a la clase más amplia de algoritmos evolutivos y son particularmente efectivos para problemas de optimización complejos, multimodales y no lineales, donde los métodos determinísticos tradicionales pueden fallar [30, pp. 20, 23].

El funcionamiento de un AG se basa en la evolución de una población de soluciones candidatas (individuos) durante varias generaciones [30, p. 27]. Cada individuo representa una solución potencial completa al problema y se codifica en un cromosoma [30, pp. 25, 39]. Para problemas de ingeniería, se utiliza comúnmente una codificación de valor real.

El componente más crítico es la función de aptitud (*fitness function*), que es la única conexión del algoritmo con el problema de dominio. Esta función toma un individuo como entrada y devuelve un valor escalar que cuantifica la calidad de esa solución [30, p. 28]. El objetivo del AG es maximizar (o minimizar) este valor.

La evolución de la población se logra mediante la aplicación iterativa de operadores genéticos [30, p. 28]:

- Selección: determina qué individuos de la población actual se reproducirán, basándose en el principio de que los individuos con mayor aptitud deben tener una mayor probabilidad de ser seleccionados [30, p. 28]. Un método robusto y común es la selección por torneo [31, 32].

- Cruce (*Crossover*): es el operador de explotación. Combina la información genética de dos individuos parentales para crear descendencia, con el objetivo de heredar rasgos beneficiosos y converger en regiones prometedoras del espacio de búsqueda [30, p. 31].
- Mutación: es el operador de exploración. Introduce cambios pequeños y aleatorios en el cromosoma de un individuo [30, p. 32]. Es esencial para mantener la diversidad genética y permitir que el algoritmo escape de óptimos locales [30, p. 32].

El poder del AG reside en el equilibrio entre la explotación (cruce) y la exploración (mutación), previniendo la convergencia prematura a soluciones subóptimas [30, pp. 19, 32].

En este proyecto, se utilizó un AG para explorar el espacio de soluciones de los parámetros biomecánicos, como se detalla en la sección 2.3.

2.3. Algoritmos de optimización

El problema central del proyecto se define como un problema de optimización multiobjetivo (MOO, *Multi-Objective Optimization*). A diferencia de la optimización mono-objetivo, la MOO busca optimizar simultáneamente dos o más funciones objetivo que, a menudo, están en conflicto.

En el contexto de este trabajo, los objetivos en conflicto fueron la maximización de la eficiencia biomecánica y la minimización de la resistencia aerodinámica, sujeto a un conjunto de restricciones biomecánicas para prevenir lesiones.

La solución a un problema MOO no es un único valor óptimo, sino un conjunto de soluciones óptimas de compromiso, conocido como el frente de Pareto. Cada solución en el frente de Pareto es óptima en el sentido de que no se puede mejorar un objetivo sin empeorar al menos otro.

La figura 2.2 ilustra el concepto de la frontera de Pareto en el contexto de los objetivos del proyecto. La superficie coloreada representa la frontera (envolvente convexa) que conecta todas las soluciones Pareto-óptimas, formando el límite del espacio de soluciones factibles. Los puntos negros sobre la superficie son las soluciones específicas evaluadas por el algoritmo genético. El punto dorado (diamante) indica la solución de compromiso recomendada, que balancea los tres objetivos simultáneamente, mientras que los puntos cuadrados (azul, rojo y verde) muestran las soluciones que optimizan cada objetivo de forma individual.

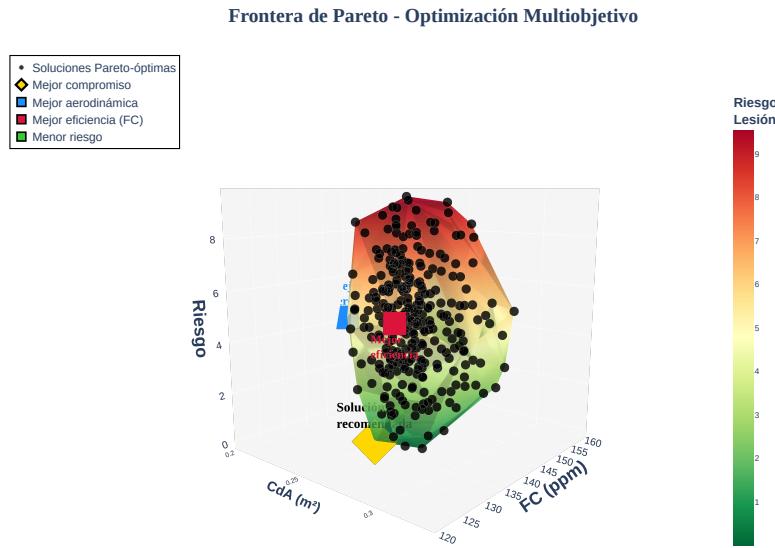


FIGURA 2.2. Frontera de Pareto tridimensional con los tres objetivos a minimizar: coeficiente aerodinámico (CdA), frecuencia cardíaca y riesgo de lesión.

2.4. Métricas de evaluación

Para evaluar la efectividad de las configuraciones recomendadas por el sistema, se definió un conjunto de métricas objetivas y subjetivas, basadas en la sección 5 (Evaluación del modelo) de la planificación [20].

2.4.1. Métricas objetivas

Las métricas objetivas son mediciones cuantitativas directas obtenidas de los sensores y del análisis cinemático.

- Eficiencia cardiovascular (FC): se define como la reducción de la frecuencia cardíaca (FC) media para un bloque de potencia constante y duración definida. Una FC menor para el mismo esfuerzo indica una mayor eficiencia. Se consideran las zonas cardíacas como referencia (Z1-Z5) para contextualizar el esfuerzo.
- Potencia (W): medición de la potencia de salida sostenida durante el intervalo de análisis. Se registra la potencia media, máxima y normalizada, considerando las zonas de potencia funcionales (FTP, *Functional Threshold Power*) del ciclista para evaluar la intensidad del esfuerzo.
- Cadencia (RPM): frecuencia de pedaleo expresada en revoluciones por minuto. Una cadencia óptima suele estar entre 80–100 RPM para la mayoría de ciclistas, aunque depende del perfil individual.
- Velocidad (km/h): velocidad de desplazamiento medida durante el test en condiciones controladas (ej. rodillo inteligente o circuito cerrado).
- Balance de potencia L/R (%): distribución de la potencia generada entre la pierna izquierda y derecha. Un balance óptimo es cercano a 50%/50%,

aunque desbalances menores al 5 % son considerados normales. Desbalances mayores pueden indicar asimetrías biomecánicas o riesgo de lesión.

- Fase de potencia (*Power Phase*): rango angular del ciclo de pedaleo donde cada pierna genera potencia positiva. Se mide en grados y permite identificar la eficiencia de la aplicación de fuerza durante el pedaleo.
- Desfase de fase de potencia (*Power Phase Offset*): diferencia angular entre el inicio de la fase de potencia de cada pierna. Valores elevados pueden indicar asimetrías en el patrón de pedaleo.
- Variabilidad cinemática: se define como la desviación estándar de ángulos articulares clave (ej. extensión de rodilla, flexión de cadera) durante múltiples ciclos de pedaleo. Una menor variabilidad sugiere un movimiento más estable, eficiente y con menor riesgo de lesiones por sobrecarga.

2.4.2. Métricas subjetivas

Las métricas subjetivas cuantifican la percepción del ciclista, lo cual es fundamental para validar el confort.

- Percepción del esfuerzo (RPE, *Rating of Perceived Exertion*): se utiliza la escala de Borg de 6 a 20. Se solicita al ciclista que valore su esfuerzo percibido en condiciones controladas (misma potencia y duración) antes y después del ajuste.
- Escalas de confort/molestia: un reporte cualitativo o en escala de 1 a 10 sobre la presencia de molestias en zonas específicas (rodillas, espalda baja, hombros, manos).

En la tabla 2.2 se resumen las métricas utilizadas para el proceso de validación.

TABLA 2.2. Tabla de definición de métricas de evaluación.

Tipo	Métrica	Definición	Unidad
Objetiva	FC (eficiencia)	FC media en zonas de potencia controladas	PPM
Objetiva	Potencia	Potencia media/normalizada en zona FTP	W
Objetiva	Cadencia	Frecuencia de pedaleo media	RPM
Objetiva	Velocidad	Velocidad en condiciones controladas	km/h
Objetiva	Balance L/R	Distribución de potencia entre piernas	%
Objetiva	Fase de potencia	Rango angular de aplicación de potencia	Grados (°)
Objetiva	Desfase de fase	Diferencia angular entre piernas	Grados (°)
Objetiva	Variabilidad cinemática	Desv. estándar de ángulos articulares	Grados (°)
Subjetiva	RPE	Escala de Borg (6–20)	Adimensional
Subjetiva	Confort	Escala de dolor (0–10)	Adimensional

Capítulo 3

Diseño e implementación

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

3.1. Análisis del software

La idea de esta sección es resaltar los problemas encontrados, los criterios utilizados y la justificación de las decisiones que se hayan tomado.

Se puede agregar código o pseudocódigo dentro de un entorno lstlisting con el siguiente código:

```
\begin{lstlisting}[caption= "un epígrafe descriptivo"]
    las líneas de código irían aquí...
\end{lstlisting}
```

A modo de ejemplo, se muestra el fragmento de código 3.1:

```

1 #define MAX_SENSOR_NUMBER 3
2 #define MAX_ALARM_NUMBER 6
3 #define MAX_ACTUATOR_NUMBER 6
4
5 uint32_t sensorValue[MAX_SENSOR_NUMBER];
6 FunctionalState alarmControl[MAX_ALARM_NUMBER]; //ENABLE or DISABLE
7 state_t alarmState[MAX_ALARM_NUMBER];           //ON or OFF
8 state_t actuatorState[MAX_ACTUATOR_NUMBER];     //ON or OFF
9
10 void vControl() {
11
12     initGlobalVariables();
13
14     period = 500 ms;
15
16     while(1) {
17
18         ticks = xTaskGetTickCount();
19
20         updateSensors();
21
22         updateAlarms();
23
24         controlActuators();
25
26         vTaskDelayUntil(&ticks , period);
27     }
}
```

²⁸ }

CÓDIGO 3.1. Pseudocódigo del lazo principal de control.

Capítulo 4

Ensayos y resultados

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

4.1. Pruebas funcionales del hardware

La idea de esta sección es explicar cómo se hicieron los ensayos, qué resultados se obtuvieron y analizarlos.

Capítulo 5

Conclusiones

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

5.1. Conclusiones generales

La idea de esta sección es resaltar cuáles son los principales aportes del trabajo realizado y cómo se podría continuar. Debe ser especialmente breve y concisa. Es buena idea usar un listado para enumerar los logros obtenidos.

En esta sección no se deben incluir ni tablas ni gráficos.

Algunas preguntas que pueden servir para completar este capítulo:

- ¿Cuál es el grado de cumplimiento de los requerimientos?
- ¿Cuán fielmente se pudo seguir la planificación original (cronograma incluido)?
- ¿Se manifestó algunos de los riesgos identificados en la planificación? ¿Fue efectivo el plan de mitigación? ¿Se debió aplicar alguna otra acción no contemplada previamente?
- Si se debieron hacer modificaciones a lo planificado ¿Cuáles fueron las causas y los efectos?
- ¿Qué técnicas resultaron útiles para el desarrollo del proyecto y cuáles no tanto?

5.2. Próximos pasos

Acá se indica cómo se podría continuar el trabajo más adelante.

Bibliografía

- [1] Holliday W. Cycling Swart J. «Cycling Biomechanics Optimization-the (R) Evolution of Bicycle Fitting». En: *PubMed (Am J Sports Med)* (2019). Publicado originalmente en *Am J Sports Med.* 2020 Feb;48(2):503-513. Accedido en: <https://pubmed.ncbi.nlm.nih.gov/31834181/>. (Visitado 06-11-2025).
- [2] David Gordon Wilson y Theodor Schmidt. *Bicycling Science*. Fourth. Cambridge, Massachusetts: The MIT Press, 2020, págs. 99-100. ISBN: 9780262538404.
- [3] David Gordon Wilson y Theodor Schmidt. *Bicycling Science*. Fourth. Ver Capítulos 2 (p. 42-47) y 4 (p. 192-193) para la descripción de equipamiento especializado de laboratorio (ergómetros, túneles de viento) usado en el análisis biomecánico. Cambridge, Massachusetts: The MIT Press, 2020. ISBN: 9780262538404.
- [4] Theo R Swart J. Holliday W Fisher J. «Static versus dynamic kinematics in cyclists: A comparison of goniometer, inclinometer and 3D motion capture». En: *PubMed* (2018). Publicado originalmente en *J Sports Med Phys Fitness.* 2018 Sep;58(9):1314-1319. Accedido en: <https://pubmed.ncbi.nlm.nih.gov/28749730/>. (Visitado 06-11-2025).
- [5] David Herrero. *RETÜL Bike fit technology – David Herrero Biomecánica*. La fecha de acceso es 6 de noviembre de 2025, según el documento fuente. 2025. URL: <https://www.davidherrero.net/sistemas/retul-bike-fit-technology> (visitado 06-11-2025).
- [6] Vicon Motion Systems. *Vicon: Award Winning Motion Capture Systems*. Accedido: 13 de noviembre de 2025. 2025. URL: <https://www.vicon.com/>.
- [7] Li FX. Fonda B Sarabon N. «Validity and reliability of different kinematics methods used for bike fitting». En: *Journal of Sports Sciences* 32.8 (2014). Accedido en ResearchGate y PubMed. DOI: 10.1080/02640414.2013.861466. El documento fuente cita [121] y [122], págs. 770-777. (Visitado 06-11-2025).
- [8] IA Center. *Gebiomized - IA Center*. Accedido: 13 de noviembre de 2025. 2025. URL: <https://iacenter.es/tecnologias/gebiomized/>.
- [9] Gebiomized. *gebioMized*. La fecha de acceso es 6 de noviembre de 2025. 2025. URL: <https://www.gebiomized.us/> (visitado 06-11-2025).
- [10] TrainingPeaks. *Bike Fitting, Technology, Biomechanics and the Future with Dr. Andy Pruitt*. La fecha de acceso es 6 de noviembre de 2025. 2025. URL: <https://www.trainingpeaks.com/coach-blog/bike-fitting-biomechanics-andy-pruitt/> (visitado 06-11-2025).
- [11] POC (Global EN). *CFD simulation and testing*. La fecha de acceso es 6 de noviembre de 2025. 2025. URL: <https://poc.com/en/journal/cfd-simulation-and-testing> (visitado 06-11-2025).
- [12] Elisa Digo et al. «A COMPUTATIONAL METHODOLOGY FOR RECUMBENT BICYCLE FITTING TO OPTIMIZE AERODYNAMIC EFFICIENCY WHILE ENSURING RIDER COMFORT». En: *International Journal of Mechanics and Control* 25 (jun. de 2024), págs. 105-114. DOI: [10.69076/jomac.2024.0015](https://doi.org/10.69076/jomac.2024.0015).

- [13] T. van Druenen. *Optimizing aerodynamic performance in cycling - TUE Research portal*. Tesis de Eindhoven University of Technology. La fecha de acceso es 6 de noviembre de 2025. 2024. URL: https://research.tue.nl/files/340281097/20241016_Druenen_van_hf.pdf (visitado 06-11-2025).
- [14] Bicycle Retailer. *AiRO Launches World's First AI-Powered, CFD-Modelled Aero Bike Fit Platform*. La fecha de acceso es 6 de noviembre de 2025. 2025. URL: <https://www.bicycleretailer.com/announcements/2025/08/18/airo-launches-world-s-first-ai-powered-cfd-modelled-aero-bike-fit-platform> (visitado 06-11-2025).
- [15] Notio. *Notio - Free the Speed – NotioArgon18support*. La fecha de acceso es 6 de noviembre de 2025. 2025. URL: <https://notio.ai/> (visitado 06-11-2025).
- [16] Global Triathlon Network (GTN). *Power Or More Aero? | GTN Experiment With The Notio Aerodynamics*. La fecha de acceso es 6 de noviembre de 2025. 2025. URL: https://www.youtube.com/watch?v=_CxZZuT7ykk (visitado 06-11-2025).
- [17] MyVeloFit. *Online Bike Fit - MyVeloFit*. La fecha de acceso es 6 de noviembre de 2025. 2025. URL: <https://www.myvelofit.com/bike-fitting/> (visitado 06-11-2025).
- [18] Bike Fast Fit. *Bike Fast Fit - Online Bike Fitting*. La fecha de acceso es 6 de noviembre de 2025. 2025. URL: <https://bikefastfit.com/> (visitado 06-11-2025).
- [19] et al. Priego-Quesada JI. «Bicycle Set-Up Dimensions and Cycling Kinematics: A Consensus Statement Using Delphi Methodology». En: *PubMed Central (Sports Med Open)* (2024). Accedido en: <https://pmc.ncbi.nlm.nih.gov/articles/PMC11561003/>. (Visitado 06-11-2025).
- [20] Rodrigo Iván Goñi. *Plan de proyecto del Trabajo Final: Optimización biomecánica del ciclismo asistida por inteligencia artificial (RG_v5)*. 2025.
- [21] Keiron O'Shea y Ryan Nash. «An Introduction to Convolutional Neural Networks». En: *arXiv preprint arXiv:1511.08458* (2015). Fecha de acceso: noviembre 11, 2025. DOI: [10.48550/arXiv.1511.08458](https://doi.org/10.48550/arXiv.1511.08458). URL: <https://arxiv.org/abs/1511.08458>.
- [22] Adrian Bulat y Georgios Tzimiropoulos. «Human pose estimation via Convolutional Part Heatmap Regression». En: *arXiv preprint arXiv:1609.01743* (2016). Fecha de acceso: noviembre 10, 2025. URL: <https://arxiv.org/html/1609.01743>.
- [23] Enrico Calleris. *Vanishing Point Detection with CNN-Based Heatmap Regression*. Medium. Fecha de acceso: noviembre 10, 2025. 2019. URL: <https://medium.com/@calleris.enrico/detecting-vanishing-point-through-cnn-based-heatmap-regression-4702991e3f5d>.
- [24] How to parse the heatmap output for the pose estimation tflite model? Stack Overflow. Pregunta de febrero 18, 2020. Fecha de acceso: noviembre 10, 2025. 2020. URL: <https://stackoverflow.com/questions/60032705/how-to-parse-the-heatmap-output-for-the-pose-estimation-tflite-model>.
- [25] LearnOpenCV. *YOLOv7 Pose vs MediaPipe in Human Pose Estimation*. Fecha de acceso: noviembre 10, 2025. URL: <https://learnopencv.com/yolov7-pose-vs-medipipe-in-human-pose-estimation/>.
- [26] Google AI Edge. *Pose landmark detection guide*. Fecha de acceso: noviembre 10, 2025. URL: https://ai.google.dev/edge/mediapipe/solutions/vision/pose_landmarker.
- [27] LearnOpenCV. *Human Pose Estimation using Keypoint RCNN in PyTorch*. Fecha de acceso: noviembre 10, 2025. URL: <https://learnopencv.com/human-pose-estimation-using-keypoint-rcnn-in-pytorch/>.

- [28] Valentin Bazarevsky, Ivan Grishchenko y et al. «BlazePose GHUM Holistic: Real-time 3D Human Landmarks and Pose Estimation». En: *arXiv preprint arXiv:2206.11678* (2022). Fecha de acceso: noviembre 10, 2025. URL: <https://arxiv.labs.arxiv.org/html/2206.11678>.
- [29] 8 Cherwai. *MODEL_ZOO.mdcbbc1ce26473cb2a5cc8f58e8ada9ae14cb410528cherwai/Detectron*. Git - Universität Hamburg. Fecha de acceso: noviembre 10, 2025. 2020. URL: https://git.informatik.uni-hamburg.de/8cherwai/Detectrontest/-/blob/cbbc1ce26473cb2a5cc8f58e8ada9ae14cb41052/MODEL_ZOO.md.
- [30] David E. Goldberg. *Genetic Algorithms in Search, Optimization and Machine Learning*. Reading, Massachusetts: Addison-Wesley Publishing Company, Inc., 1989. ISBN: 0-201-15767-5.
- [31] UPV. *Selección de individuos en Algoritmos Genéticos*. Fecha de acceso: noviembre 10, 2025. URL: <https://www.youtube.com/watch?v=LPsm1RT1DqQ>.
- [32] Wikipedia. *Selección por torneos - Wikipedia, la enciclopedia libre*. Fecha de acceso: noviembre 10, 2025. URL: https://es.wikipedia.org/wiki/Selección_por_torneos.