

# Optimización biomecánica del ciclismo asistida por inteligencia artificial

Ing. Rodrigo Iván Goñi

**Carrera de Especialización en Inteligencia Artificial**

**Director:** MSc. Fernando Corteggiano

**Jurados:**

PhD. David Deyong  
Jurado 2 (pertenencia)  
Jurado 3 (pertenencia)

*Ciudad de Mendoza, abril de 2025*



## *Resumen*

En la presente memoria se describe el desarrollo de un sistema inteligente y personalizado para la optimización de parámetros biomecánicos de una bicicleta. Este trabajo pretende maximizar la eficiencia del pedaleo y minimizar el riesgo de lesiones, con el fin de democratizar el acceso a una biomecánica de precisión con un bajo costo. Para su implementación fueron esenciales los conocimientos en detección de pose por redes neuronales, análisis cinemático y algoritmos de optimización multiobjetivo.



## *Agradecimientos*

Esta sección es para agradecimientos personales y es totalmente **OPCIONAL**.



# Índice general

<b>Resumen</b>	<b>I</b>
<b>1. Introducción general</b>	<b>1</b>
1.1. Contexto y problemática	1
1.2. Estado del arte	2
1.2.1. El estándar cinemático: captura de movimiento 3D y 4D	2
1.2.2. Cuantificación de la interfaz: mapeo avanzado de presión	3
1.2.3. El imperativo aerodinámico y la democratización del análisis	4
1.2.4. Síntesis y limitaciones del estado del arte	4
1.3. Motivación y propósito	5
1.4. Objetivos y alcance	5
<b>2. Introducción específica</b>	<b>7</b>
2.1. Marco teórico	7
2.1.1. Visión artificial para estimación de pose	7
2.1.2. Algoritmos genéticos	8
2.2. Algoritmos de optimización	9
2.3. Métricas de evaluación	10
2.3.1. Métricas objetivas	10
2.3.2. Métricas subjetivas	11
<b>3. Diseño e implementación</b>	<b>13</b>
3.1. Metodología	13
3.2. Arquitectura del <i>pipeline</i>	14
3.2.1. Entrada de datos: adquisición multimodal	16
Subsistema de video y restricciones ópticas	16
Entorno de análisis y procesamiento de señales	17
3.2.2. Procesamiento y análisis: reconstrucción digital	17
Detección de pose neuronal	17
Sincronización temporal (algoritmo de correlación de coherencia)	17
3.2.3. Modelado y simulación: física computacional	18
Estimación aerodinámica ( $C_d A$ )	18
Dinámica inversa plana	18
3.2.4. Optimización multi-objetivo: algoritmo genético	18
Funciones objetivo	18
Configuración del algoritmo	19
3.2.5. Salida y retroalimentación	19
3.3. Adquisición de datos	19
3.4. Modelado cinemático y biomecánico	20
3.5. Modelado del sistema	20
3.5.1. Detección de pose	21

3.5.2. Motor de optimización . . . . .	21
3.6. Reporte de recomendaciones . . . . .	21
<b>4. Ensayos y resultados</b>	<b>23</b>
4.1. Pruebas funcionales del hardware . . . . .	23
<b>5. Conclusiones</b>	<b>25</b>
5.1. Conclusiones generales . . . . .	25
5.2. Próximos pasos . . . . .	25
<b>Bibliografía</b>	<b>27</b>



# Índice de figuras

1.1. Ilustración de la problemática de un mal ajuste biomecánico. . . . .	1
1.2. Ejemplo de un sistema profesional de análisis biomecánico en laboratorio. . . . .	2
2.1. Frontera de Pareto tridimensional con los tres objetivos a minimizar: coeficiente aerodinámico (CdA), frecuencia cardíaca y riesgo de lesión. . . . .	10
3.1. Diagrama de flujo de la metodología CRISP-DM adaptada para el trabajo. . . . .	14
3.2. Diagrama en bloques detallado de la arquitectura del <i>pipeline</i> y el flujo de datos multimodal. . . . .	15



# Índice de tablas

2.1. Tabla comparativa de modelos de estimación de pose. . . . .	8
2.2. Tabla de definición de métricas de evaluación. . . . .	11
3.1. Parámetros biomecánicos y rangos óptimos definidos para el modelo.	21
3.2. Parámetros de configuración del algoritmo de optimización. . . . .	22



*Dedicado a... [OPCIONAL]*



# Capítulo 1

## Introducción general

Este capítulo presenta una introducción general al trabajo. Primero, se expone el contexto y la problemática de la biomecánica en el ciclismo. A continuación, se analiza el estado del arte de las soluciones de ajuste, o *bike fitting*, y sus limitaciones actuales. Se detalla la motivación y el propósito que impulsan el desarrollo de una nueva solución. Finalmente, se definen los objetivos específicos y el alcance del prototipo propuesto.

### 1.1. Contexto y problemática

La biomecánica en el ciclismo es un factor fundamental para mejorar el rendimiento y prevenir lesiones [1]. Su principio se basa en la adaptación de la bicicleta a las características físicas del ciclista. Un ajuste incorrecto no solo puede causar lesiones, sino también una disminución en la potencia de salida que puede alcanzar hasta un 20 % [2]. En la figura 1.1 se ilustra esta problemática.




FIGURA 1.1. Ilustración de la problemática de un mal ajuste biomecánico.

Sin embargo, el acceso a un análisis biomecánico profesional presenta barreras significativas. Las soluciones actuales suelen ser costosas, tienen baja disponibilidad y exigen visitas a laboratorios especializados [3].

## 1.2. Estado del arte

El *bike fitting*, o ajuste biomecánico de la bicicleta, ha transitado desde un proceso artesanal basado en la goniometría estática y la experiencia subjetiva, hacia una ciencia de datos multimodal y de alta precisión [4]. Las soluciones convencionales, basadas en un análisis estático y puntual, dependen en gran medida de la experiencia del biomecánico. La recomendación de repetir el ajuste anualmente, sumada al alto costo y la escasa disponibilidad, provoca que la mayoría de los ciclistas no mantengan una configuración óptima.

Los sistemas profesionales de laboratorio, como el que se observa en la figura 1.2, ejemplifican este enfoque. El estado del arte actual ya no se define por una única tecnología, sino por la convergencia e integración de múltiples flujos de datos. Este análisis sintetiza el panorama de las soluciones de vanguardia, que se pueden agrupar en cuatro pilares tecnológicos principales que definen la práctica avanzada.




FIGURA 1.2. Ejemplo de un sistema profesional de análisis biomecánico en laboratorio.

### 1.2.1. El estándar cinemático: captura de movimiento 3D y 4D

La evolución fundamental en el *bike fitting* ha sido el paso de las mediciones estáticas a las dinámicas. Los métodos tradicionales, que emplean goniómetros manuales o análisis de vídeo en 2D con el ciclista detenido, han demostrado ser insuficientes [4]. Estos métodos no logran capturar la biomecánica real del ciclista bajo carga, es decir, mientras pedalea activamente [5].

El ajuste dinámico tridimensional (3D) se considera el estándar que ofrece las mayores garantías. Sistemas como Retül o Vicon [5, 6] se han establecido como referentes y utilizan múltiples cámaras infrarrojas para rastrear marcadores en puntos anatómicos clave en tiempo real. Esto permite un análisis preciso del movimiento en los tres planos del espacio (sagital, frontal, transversal), lo que proporciona una imagen completa de la cinemática del ciclista que es imposible de obtener con métodos más simples [5].



La superioridad del 3D no es meramente cualitativa, ha sido cuantificada rigurosamente. Un estudio fundamental de Fonda, Sarabon y Li [7] comparó directamente los métodos cinemáticos. El hallazgo clave fue que, en comparación con el estándar 3D, el análisis 2D subestima de forma estadísticamente significativa el ángulo de la articulación de la rodilla. Esta subestimación sistemática es un error inherente a la proyección de un movimiento tridimensional en un plano bidimensional. El estudio determinó la necesidad de añadir un factor de corrección específico de  $2,2^\circ$  al valor 2D para aproximar el valor real 3D [7]. Esto subraya la imprecisión inherente de los métodos 2D para una verdadera optimización biomecánica.

El estado del arte ha avanzado más allá de la simple dicotomía estático vs. dinámico. El análisis no solo debe ser dinámico, sino también funcional, es decir, realizado bajo cargas de trabajo (potencia) relevantes. Una revisión sistemática de 2019 [1] sobre la biomecánica del ciclismo proporciona una visión crítica: la cinemática del ciclista se ve influenciada significativamente por la carga de trabajo. A medida que aumenta la potencia, los ciclistas exhiben cinemáticas compensatorias para mantener la producción de fuerza. Por lo tanto, un ajuste realizado a baja intensidad puede ser biomecánicamente inválido o subóptimo para las condiciones de competición del ciclista. La revisión establece rangos óptimos para el Ángulo de Flexión de Rodilla (KFA) medido dinámicamente, que se reduce de  $33\text{--}43^\circ$  a baja intensidad, a un rango de  $30\text{--}40^\circ$  a alta intensidad [1].

### 1.2.2. Cuantificación de la interfaz: mapeo avanzado de presión

Si bien la cinemática 3D describe cómo se mueve el cuerpo del ciclista en el espacio, no puede describir cómo el ciclista interactúa con la bicicleta. El mapeo avanzado de presión [8] es la tecnología de vanguardia diseñada para cuantificar la estabilidad y la distribución de la fuerza en los tres puntos de contacto principales: sillín, pies y manillar.

Empresas como Gebiomized [9] lideran este dominio con alfombrillas de sensores flexibles y de alta resolución que proporcionan información previamente inconmensurable. La aplicación más crítica es el análisis del sillín. Más allá de la simple comodidad subjetiva, el sistema mide la distribución de la presión (media y máxima) y las asimetrías izquierda/derecha. Sin embargo, la métrica más importante generada es el Centro de Movimiento y el Patrón de Rastreo Pélvico (*Pelvic Tracking*). El sistema mapea cómo se mueve el centro de presión del ciclista sobre el sillín mientras pedalea [9].

Esta tecnología proporciona el vínculo causal crucial entre la cinemática y la estabilidad de la interfaz. A menudo, un movimiento cinemático aberrante de la rodilla (detectado por un sistema 3D) no es un problema de la rodilla en sí. Es un síntoma. La causa raíz suele ser la inestabilidad pélvica. La tecnología de mapeo de presión es la única herramienta que puede diagnosticar y cuantificar objetivamente esta inestabilidad pélvica. De manera similar, esta tecnología se aplica a las plantillas (para analizar la transferencia de potencia y estabilizar el pie como una palanca rígida [10]) y al *cockpit* (para mitigar la fatiga y las neuropatías en las extremidades superiores) [9].

### 1.2.3. El imperativo aerodinámico y la democratización del análisis

Para el ciclismo de rendimiento, la biomecánica es solo la mitad de la ecuación. Existe un conflicto central: la posición más aerodinámica (típicamente más baja y estrecha) a menudo restringe la biomecánica de la producción de potencia y compromete el confort [10]. El estado del arte busca cuantificar y optimizar este equilibrio.

Históricamente, esto requería costosas pruebas en túneles de viento físicos [11]. La primera evolución fue la Dinámica de Fluidos Computacional (CFD) [12, 13]. Las soluciones más recientes integran CFD con Inteligencia Artificial (IA). Plataformas emergentes como AiRO [14] se describen como el primer sistema de *bike-fit* modelado por CFD e impulsado por IA. El sistema genera un modelo 3D del ciclista y ejecuta un análisis CFD en la nube para calcular la resistencia aerodinámica (CdA) en minutos [14]. Un enfoque alternativo o complementario son los sensores aerodinámicos portátiles en tiempo real, como el Notio Aerometer. Este dispositivo utiliza un tubo de Pitot, GPS y una conexión a un medidor de potencia para calcular el CdA de referencia del ciclista en condiciones del mundo real [15, 16].

Paralelamente a estos sistemas de alta especialización, ha surgido una tendencia de democratización del *bikefitting* mediante aplicaciones de *smartphone*. Plataformas como MyVeloFit [17] y Bike Fast Fit [18] ofrecen análisis biomecánicos por una fracción del costo de un *fit* de laboratorio. Su innovación más significativa (particularmente MyVeloFit) es la integración de evaluaciones de movilidad funcional [19]. El proceso comienza con el usuario que realiza una serie de evaluaciones de movilidad. La IA personaliza la ventana de ajuste objetivo basándose en los resultados de la flexibilidad individual del usuario [17].

Esto, sin embargo, presenta un conflicto académico fundamental. En esencia, estas aplicaciones siguen siendo sistemas de cinemática 2D. Esto las pone en contradicción directa con los hallazgos (como los de Fonda et al. [7]) que establecieron que el 2D subestima sistemáticamente los ángulos clave. La pregunta crítica que sigue siendo un área clave para la investigación futura, es si los algoritmos de IA pueden compensar adecuadamente los errores inherentes de perspectiva y paralaje de una captura 2D.

### 1.2.4. Síntesis y limitaciones del estado del arte

El análisis del estado del arte revela una clara trayectoria: una evolución desde la medición de ángulos estáticos hacia la creación de un perfil dinámico y multimodal del sistema ciclista-bicicleta. El ajuste óptimo ya no es un conjunto estático de coordenadas, sino un equilibrio dinámico validado a través de múltiples capas de datos.

El desafío principal en este campo es encontrar el balance óptimo entre la posición que maximiza la velocidad y aquella que minimiza el esfuerzo y el riesgo de lesiones. Frecuentemente, la postura más aerodinámica no es la más sostenible a largo plazo. El papel del profesional ha pasado de ser un técnico a ser un integrador de datos, que debe sopesar métricas a menudo contradictorias.

Las limitaciones de las soluciones de vanguardia (sistemas 3D, mapeo de presión, CFD) son su alto costo y su dependencia de un entorno de laboratorio. Esto define el enfoque de las soluciones tradicionales: un análisis estático y puntual.

Esta aproximación ha impedido una verdadera optimización biomecánica continua para el ciclista, lo que define la problemática central que motiva el presente trabajo.

### 1.3. Motivación y propósito

La motivación de este trabajo surge de la necesidad de evitar las limitaciones del estado del arte, detalladas en la sección 1.2. El alto costo, la baja disponibilidad y el enfoque estático de las soluciones tradicionales han impedido una verdadera optimización biomecánica continua para el ciclista.

En este contexto, se reconoce que el ajuste debe ser un proceso dinámico [4, 7]. La necesidad de un ajuste frecuente obedece a que la práctica constante del deporte genera adaptaciones fisiológicas en el ciclista. Estas adaptaciones incluyen una mejora en la capacidad de elongación y flexibilidad muscular, lo que modifica los rangos de movimiento óptimos para el pedaleo. Por consiguiente, la configuración ideal de la bicicleta evoluciona con el progreso físico del deportista y exige una reevaluación periódica.

El valor fundamental de la solución propuesta radica en la capacidad de ofrecer al ciclista la realización de ajustes frecuentes y a un costo significativamente menor que las alternativas tradicionales. Esta aproximación permite una mejora continua del rendimiento y una gestión activa de la prevención de lesiones al considerar la evolución de las capacidades físicas del deportista.

El propósito de este trabajo es desarrollar un sistema inteligente y personalizado que enfrente el desafío de la optimización multiobjetivo. El sistema integra la detección de pose mediante redes neuronales y el análisis exhaustivo de datos provenientes de sensores de ciclismo. Se buscó optimizar de forma integral los parámetros biomecánicos de la bicicleta. En esencia, se persiguió maximizar la potencia y eficiencia del pedaleo, minimizar el riesgo de lesiones, y equilibrar estos factores con la aerodinámica para alcanzar la máxima velocidad posible.

### 1.4. Objetivos y alcance

El objetivo principal de este trabajo fue desarrollar un prototipo de un sistema inteligente que optimice los parámetros biomecánicos de la bicicleta. Se buscó maximizar la potencia y eficiencia del pedaleo, minimizar el riesgo de lesiones y equilibrar estos factores con la aerodinámica.

El alcance del trabajo incluyó:

- El desarrollo de un sistema de optimización personalizado que proporciona recomendaciones para el ajuste biomecánico de la bicicleta.
- Un ciclo continuo de análisis y retroalimentación que incluye la captura de datos (video y sensores), el análisis de movimiento mediante estimación de pose 2D, y un modelo biomecánico.
- Un algoritmo de optimización integral para lograr el equilibrio entre ajuste biomecánico, aerodinámica y prevención de lesiones.
- La generación de un reporte con recomendaciones claras para que el usuario pueda ajustar la bicicleta.

El presente trabajo no incluyó:

- El desarrollo de hardware personalizado para la captura de datos. Se utiliza la integración con sensores comerciales existentes.
- El entrenamiento de la red neuronal de detección de pose desde cero. Se espera utilizar o adaptar redes neuronales preexistentes.
- La simulación de factores externos complejos, como condiciones climáticas extremas.

## Capítulo 2

# Introducción específica

En este capítulo se presenta el marco teórico que sustentó el desarrollo del trabajo. Se detallan las tecnologías de *software* seleccionadas para el análisis y la optimización, y las métricas definidas para la validación del sistema. El contenido de este capítulo se basa en la planificación y los conceptos establecidos en el documento de gestión del proyecto [20].

### 2.1. Marco teórico

El desarrollo del sistema se fundamentó en dos pilares tecnológicos principales: la visión artificial para el análisis cinemático y los algoritmos genéticos para la optimización.

#### 2.1.1. Visión artificial para estimación de pose

Para la extracción de las coordenadas 2D de los puntos clave del ciclista desde la captura de video, se realizó un análisis de las herramientas de estimación de pose (*pose estimation*) disponibles. Se evaluaron modelos preentrenados como Keypoint R-CNN [21] y MediaPipe [22], mencionados en la planificación del proyecto [20].

Estos modelos utilizan redes neuronales convolucionales profundas (CNN) para identificar y localizar articulaciones humanas clave (ej. codos, rodillas, tobillos) en cada fotograma. Las CNN se han convertido en el estándar en tareas de visión por computador, con un diseño inspirado en el córtex visual humano. Su principio fundamental es la abstracción jerárquica de características [23]. Las capas iniciales detectan rasgos de bajo nivel como bordes y texturas, que se componen en representaciones más complejas en capas sucesivas.

El paradigma dominante actual para esta tarea no es la regresión directa de coordenadas, la que demostró ser difícil, particularmente ante oclusiones [24]. En su lugar, el problema se reformula como la detección basada en mapas de calor (*heat-maps*) [25]. En este enfoque, la CNN genera un conjunto de mapas de calor 2D, uno por cada articulación [26]. Cada mapa de calor funciona como una distribución de probabilidad espacial, donde el valor de cada píxel representa la confianza de que la articulación se ubique allí. Este método permite codificar la incertidumbre: una articulación visible genera un pico de alta confianza, mientras que una articulación oculta se representa por un pico más difuso y bajo.

Finalmente, se seleccionó el modelo MediaPipe BlazePose. Esta decisión no se basó únicamente en la precisión, sino en dos justificaciones de dominio específicas. En primer lugar, su alineación con la tarea: BlazePose es un rastreador

(*tracker*) optimizado para la coherencia temporal en vídeo [27], a diferencia de los modelos que detectan en cada fotograma. En segundo lugar, su alineación con el dominio biomecánico: el modelo predice una topología de 33 *landmarks* 3D [28] que incluye puntos clave en pies y talones, elementos indispensables para el análisis biomecánico del ciclismo que no están presentes en las 17 articulaciones de los modelos COCO [29].

En la tabla 2.1 se presenta una comparativa de los modelos evaluados.

TABLA 2.1. Tabla comparativa de modelos de estimación de pose.

Modelo		mAP	FPS	Observaciones
MediaPipe BlazePose		62.6–68.1 en 17 kpts [30]	~30 FPS CPU [27]	Optimizado para <i>tracking</i> en vídeo. Topología de 33 <i>landmarks</i> 3D [28].
Keypoint CNN	R-COCO	63.1 kp. AP en COCO [21]	~5 FPS [21]	Alta precisión. Costo escala linealmente con número de personas [27].

### 2.1.2. Algoritmos genéticos

Los algoritmos genéticos (AG, *Genetic Algorithms*) son metaheurísticas de búsqueda inspiradas en el proceso de selección natural [31]. Pertenecen a la clase más amplia de algoritmos evolutivos y son particularmente efectivos para problemas de optimización complejos, multimodales y no lineales, donde los métodos determinísticos tradicionales pueden fallar [31].

El funcionamiento de un algoritmo genético se basa en la evolución de una población de soluciones candidatas (individuos) durante varias generaciones [31]. Cada individuo representa una solución potencial completa al problema y se codifica en un cromosoma [31]. Para problemas de ingeniería, se utiliza comúnmente una codificación de valor real.

El componente más crítico es la función de aptitud (*fitness function*), que es la única conexión del algoritmo con el problema de dominio. Esta función toma un individuo como entrada y devuelve un valor escalar que cuantifica la calidad de esa solución [31]. El objetivo del algoritmo genético es maximizar (o minimizar) este valor.

La evolución de la población se logra mediante la aplicación iterativa de operadores genéticos [31]:

- Selección: se determina qué individuos de la población actual se reproducirán, con base en el principio de que los individuos con mayor aptitud deben tener una mayor probabilidad de ser seleccionados [31]. Un método robusto y común es la selección por torneo [32, 33].
- Cruce (*crossover*): es el operador de explotación. Combina la información genética de dos individuos parentales para crear descendencia, con el objetivo de heredar rasgos beneficiosos y converger en regiones prometedoras del espacio de búsqueda [31].
- Mutación: es el operador de exploración. Introduce cambios pequeños y aleatorios en el cromosoma de un individuo [31]. Es esencial para mantener

la diversidad genética y permitir que el algoritmo escape de óptimos locales [31].

El poder del algoritmo genético reside en el equilibrio entre la explotación (cruce) y la exploración (mutación), lo que previene la convergencia prematura a soluciones subóptimas [31].

En este trabajo, se utilizó un algoritmo genético para explorar el espacio de soluciones de los parámetros biomecánicos, como se detalla en la sección 2.2.

## 2.2. Algoritmos de optimización

El problema central del trabajo se definió como un problema de optimización multiobjetivo (MOO, *Multi-Objective Optimization*). A diferencia de la optimización mono-objetivo, la MOO busca optimizar simultáneamente dos o más funciones objetivo que, a menudo, están en conflicto.

En el contexto de este trabajo, los objetivos en conflicto fueron la maximización de la eficiencia biomecánica y la minimización de la resistencia aerodinámica, sujetos a un conjunto de restricciones biomecánicas para prevenir lesiones.

La solución a un problema MOO no es un único valor óptimo, sino un conjunto de soluciones óptimas de compromiso, conocido como el frente de Pareto. Cada solución en el frente de Pareto es óptima en el sentido de que no se puede mejorar un objetivo sin empeorar al menos otro.

La figura 2.1 ilustra el concepto de la frontera de Pareto en el contexto de los objetivos del trabajo. La superficie coloreada representa la frontera (envolvente convexa) que conecta todas las soluciones Pareto-óptimas, formando el límite del espacio de soluciones factibles. Los puntos negros sobre la superficie son las soluciones específicas evaluadas por el algoritmo genético. El punto dorado (diamante) indica la solución de compromiso recomendada, que balancea los tres objetivos simultáneamente, mientras que los puntos cuadrados (azul, rojo y verde) muestran las soluciones que optimizan cada objetivo de forma individual.




FIGURA 2.1. Frontera de Pareto tridimensional con los tres objetivos a minimizar: coeficiente aerodinámico (CdA), frecuencia cardíaca y riesgo de lesión.

## 2.3. Métricas de evaluación

Para evaluar la efectividad de las configuraciones recomendadas por el sistema, se definió un conjunto de métricas objetivas y subjetivas, basadas en la sección 5 (evaluación del modelo) de la planificación [20].

### 2.3.1. Métricas objetivas

Las métricas objetivas son mediciones cuantitativas directas obtenidas de los sensores y del análisis cinemático.

- Eficiencia cardiovascular (FC): se define como la reducción de la frecuencia cardíaca (FC) media para un bloque de potencia constante y duración definida. Una FC menor para el mismo esfuerzo indica una mayor eficiencia. Se consideran las zonas cardíacas como referencia (Z1-Z5) para contextualizar el esfuerzo.
- Potencia (W): medición de la potencia de salida sostenida durante el intervalo de análisis. Se registra la potencia media, máxima y normalizada, considerando las zonas de potencia funcionales (FTP, *Functional Threshold Power*) del ciclista para evaluar la intensidad del esfuerzo.
- Cadencia (RPM): frecuencia de pedaleo expresada en revoluciones por minuto. Una cadencia óptima suele estar entre 80–100 RPM para la mayoría de ciclistas, aunque depende del perfil individual.
- Velocidad (km/h): velocidad de desplazamiento medida durante el test en condiciones controladas (ej. rodillo inteligente o circuito cerrado).
- Balance de potencia L/R (%): distribución de la potencia generada entre la pierna izquierda y derecha. Un balance óptimo es cercano a 50%/50%,



aunque desbalances menores al 5 % son considerados normales. Desbalances mayores pueden indicar asimetrías biomecánicas o riesgo de lesión.

- Fase de potencia (*Power Phase*): rango angular del ciclo de pedaleo donde cada pierna genera potencia positiva. Se mide en grados y permite identificar la eficiencia de la aplicación de fuerza durante el pedaleo.
- Desfase de fase de potencia (*Power Phase Offset*): diferencia angular entre el inicio de la fase de potencia de cada pierna. Valores elevados pueden indicar asimetrías en el patrón de pedaleo.
- Variabilidad cinemática: se define como la desviación estándar de ángulos articulares clave (ej. extensión de rodilla, flexión de cadera) durante múltiples ciclos de pedaleo. Una menor variabilidad sugiere un movimiento más estable, eficiente y con menor riesgo de lesiones por sobrecarga.

### 2.3.2. Métricas subjetivas

Las métricas subjetivas cuantifican la percepción del ciclista, lo que es fundamental para validar el confort.

- Percepción del esfuerzo (RPE, *Rating of Perceived Exertion*): se utiliza la escala de Borg de 6 a 20. Se solicita al ciclista que valore su esfuerzo percibido en condiciones controladas (misma potencia y duración) antes y después del ajuste.
- Escalas de confort/molestia: un reporte cualitativo o en escala de 1 a 10 sobre la presencia de molestias en zonas específicas (rodillas, espalda baja, hombros, manos).

En la tabla 2.2 se resumen las métricas utilizadas para el proceso de validación.

TABLA 2.2. Tabla de definición de métricas de evaluación.

Tipo	Métrica	Definición	Unidad
Objetiva	FC (eficiencia)	FC media en zonas de potencia controladas	PPM
Objetiva	Potencia	Potencia media/normalizada en zona FTP	W
Objetiva	Cadencia	Frecuencia de pedaleo media	RPM
Objetiva	Velocidad	Velocidad en condiciones controladas	km/h
Objetiva	Balance L/R	Distribución de potencia entre piernas	%
Objetiva	Fase de potencia	Rango angular de aplicación de potencia	Grados
Objetiva	Desfase de fase	Diferencia angular entre piernas	Grados
Objetiva	Variabilidad cinemática	Desv. estándar de ángulos articulares	Grados
Subjetiva	RPE	Escala de Borg (6–20)	Adim.
Subjetiva	Confort	Escala de dolor (0–10)	Adim.



## Capítulo 3

# Diseño e implementación

En este capítulo se presenta el diseño e implementación del sistema de optimización biomecánica desarrollado en este trabajo. Se describe la metodología empleada para estructurar el trabajo, la arquitectura del sistema propuesto y los módulos que lo componen. La exposición se organiza de manera secuencial, desde la adquisición de datos hasta la generación del reporte final de recomendaciones.

### 3.1. Metodología

Para la gestión y ejecución de este trabajo, se adaptó la metodología CRISP-DM [34] (*Cross-Industry Standard Process for Data Mining*). Esta adaptación fue necesaria para alinear las fases estándar de un trabajo de minería de datos con los objetivos específicos del trabajo de optimización biomecánica asistida por inteligencia artificial, como se describe en la sección 8 del documento de planificación [20].

El modelo se reestructuró en las siguientes fases principales, que fueron ajustadas al contexto del trabajo:

- Comprensión del negocio y del problema biomecánico.
- Comprensión y adquisición de los datos (video, sensores de rendimiento y datos antropométricos).
- Preparación y preprocesamiento de los datos, que incluyó la extracción de pose y el filtrado de señales.
- Modelado y simulación biomecánica y aerodinámica.
- Evaluación de las soluciones generadas por el optimizador (análisis del frente de Pareto).
- Despliegue, que fue materializado en la generación del reporte de recomendaciones para el ciclista.

La figura 3.1 muestra el diagrama de flujo de la metodología implementada.




FIGURA 3.1. Diagrama de flujo de la metodología CRISP-DM adaptada para el trabajo.

### 3.2. Arquitectura del *pipeline*

En esta sección se detalla el diseño arquitectónico del sistema desarrollado. La solución fue estructurada como un flujo de trabajo lineal con retroalimentación de control cerrado, concebido para transformar flujos de datos estocásticos y asíncronos provenientes de video y sensores en recomendaciones biomecánicas accionables y deterministas. La arquitectura modular permitió el desacoplamiento estricto de las capas de percepción, modelado físico y razonamiento algorítmico, lo que facilitó la actualización independiente de los modelos de redes neuronales o los parámetros del algoritmo genético sin comprometer la integridad operativa del sistema global.

El flujo lógico de datos, conceptualizado en el diagrama de bloques de la Figura 3.2, se organiza en cinco etapas secuenciales críticas que abordan desde la física de la adquisición de la señal hasta la convergencia matemática de la solución óptima:

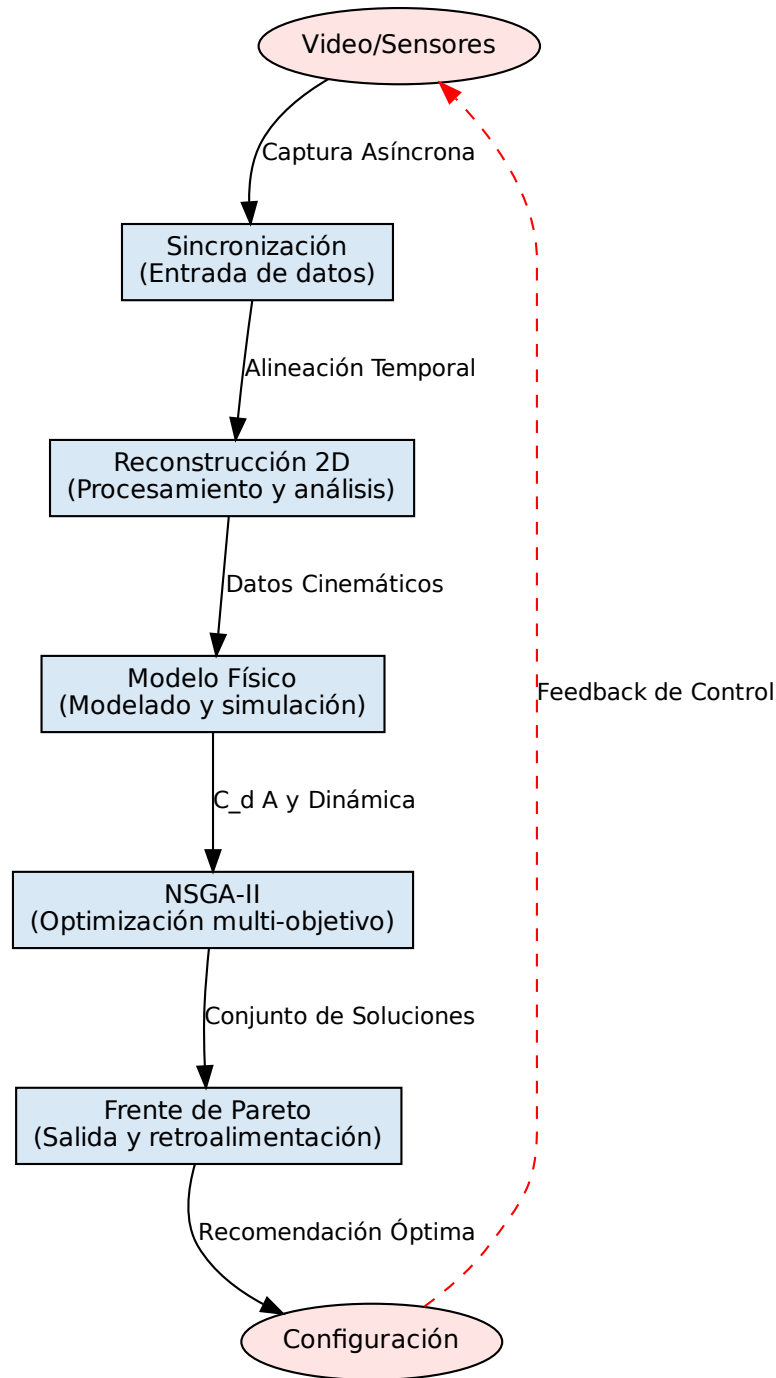


FIGURA 3.2. Diagrama en bloques detallado de la arquitectura del pipeline y el flujo de datos multimodal.

1. Entrada de datos (capa de adquisición): módulo de abstracción de hardware encargado de la captura sincronizada de fuentes heterogéneas, que gestionó *buffers* circulares para video de alta velocidad y telemetría mediante protocolos inalámbricos ANT+ [35] y BLE (Bluetooth Low Energy) [36].

2. Procesamiento y análisis (capa de percepción): etapa de acondicionamiento de señal donde se ejecutó la inferencia de la red neuronal de detección de pose, se realizó la alineación temporal mediante correlación cruzada de señales y se aplicó filtrado digital selectivo para la reconstrucción cinemática.
3. Modelado y simulación (capa física): instanciación del gemelo digital del ciclista, resolución del problema de dinámica inversa plana y estimación del coeficiente aerodinámico ( $C_d A$ ).
4. Optimización multi-objetivo (capa de razonamiento): núcleo algorítmico donde un algoritmo genético exploró estocásticamente el espacio de configuraciones geométricas para resolver el conflicto entre confort biomecánico, eficiencia de potencia y resistencia aerodinámica.
5. Salida y retroalimentación (capa de interfaz): generación del frente de Pareto, visualización sobre el flujo de video original y cierre del ciclo de control tras la verificación del ajuste físico.

Esta arquitectura fue diseñada para ejecutarse completamente en el borde, lo que permitió minimizar la latencia de inferencia y garantizar la privacidad de los datos biomecánicos del ciclista al mantener todo el procesamiento local sin necesidad de conexión a servicios externos.

### 3.2.1. Entrada de datos: adquisición multimodal

Este módulo actuó como la interfaz física con el entorno, lo que permitió recolectar datos de dominios temporales dispares: el dominio óptico (video) y el dominio de sensores inerciales/potencia. La sincronización de estos dominios fue el desafío fundamental de esta etapa.

#### Subsistema de video y restricciones ópticas

La captura de video es el sustrato fundamental para la reconstrucción cinemática 2D. A diferencia de la grabación convencional, este módulo impuso restricciones estrictas de hardware para garantizar la integridad de los mapas de calor generados por la red neuronal en etapas posteriores:

- Velocidad de obturación: se impuso un tiempo de exposición máximo de  $t_{exp} \leq 1/500$  s. Esto fue crítico para eliminar el desenfoque de movimiento (*motion blur*) en los marcadores anatómicos (especialmente el maléolo lateral citepRadiologia2013 y el quinto metatarso [37]), que alcanzaron velocidades angulares máximas  $\omega_{max}$  en los puntos muertos del ciclo de pedaleo. El desenfoque en estas fases introdujo un error sistemático no gaussiano en la inferencia de la posición articular.
- Tasa de fotogramas: se requirió una frecuencia de muestreo mínima de  $f_s \geq 60$  FPS para cumplir con el teorema de Nyquist-Shannon aplicado a la cinemática del pedaleo, donde los armónicos de movimiento significativos se encuentran por debajo de 15 Hz.
- Normalización de entrada: la resolución de entrada se redimensionó dinámicamente para coincidir con el tensor de entrada de la CNN, lo que utilizó interpolación bicúbica para evitar artefactos de degradación de la señal (*aliasing*).

### Entorno de análisis y procesamiento de señales

El sistema migró de una interfaz de telemetría propietaria a un entorno basado en GoldenCheetah [38], lo que utilizó su motor de ejecución de Python integrado como núcleo de procesamiento. Esta arquitectura permitió la manipulación de datos de alto nivel, lo que superó las limitaciones del procesamiento de tramas crudas.

En lugar de calcular la potencia media  $\bar{P}$  mediante diferencias de acumulados a nivel de byte, el sistema utilizó las estructuras de datos internas de GoldenCheetah, las cuales garantizaron la integridad y sincronización temporal de las muestras. La implementación se basó en dos pilares documentados en la API de GoldenCheetah:

- Acceso a datos: recuperación de actividades y series temporales mediante funciones nativas, lo que aseguró la coherencia de los datos independientemente del protocolo de transmisión (ANT+ o BLE).
- Procesadores personalizados: implementación de algoritmos definidos por el usuario que operaron sobre la señal de potencia  $P(t)$  ya depurada, lo que permitió el cálculo de métricas derivadas complejas en un entorno interpretado de Python.

#### 3.2.2. Procesamiento y análisis: reconstrucción digital

Este módulo transformó los datos brutos (imágenes y bytes) en señales biomecánicas estructuradas, limpias y sincronizadas.

#### Detección de pose neuronal

Se empleó una arquitectura de aprendizaje profundo para inferir la ubicación probabilística de 33 puntos clave del cuerpo. Para adaptar la red de propósito general al contexto específico del ciclismo, se implementó un filtro de Prior Cinemático.

Dado que el ciclismo con calas automáticas constituye una cadena cinética cerrada (los pies están fijos a los pedales y describen una trayectoria circular fija), la longitud de los segmentos óseos debe permanecer invariante en el tiempo. El sistema penalizó y corrigió detecciones que violaron la antropometría del sujeto:

$$|L_{seg}(t) - \mu_{L_{seg}}| > \epsilon \Rightarrow \text{Corrección por cinemática inversa} \quad (3.1)$$

Donde  $L_{seg}(t)$  es la longitud euclidiana del segmento en el instante  $t$  y  $\mu_{L_{seg}}$  es la longitud media calibrada.

#### Sincronización temporal (algoritmo de correlación de cadencia)

Un desafío arquitectónico mayor fue alinear el video (muestreado a 60-240 Hz) con la telemetría (muestreada a 4 Hz), ya que poseen relojes independientes y latencias de transmisión variables. El *pipeline* implementó un algoritmo de alineación basado en la cadencia:

1. Se extrajo una señal de “cadencia visual” ( $\omega_{vis}$ ) al analizar la periodicidad de la coordenada vertical de la rodilla ( $y_{knee}$ ) mediante Transformada de Fourier de Tiempo Corto (STFT).

2. Se obtuvo la señal de cadencia del sensor de potencia ( $\omega_{sens}$ ).
3. Se calculó la correlación cruzada normalizada  $R_{vs}(\tau)$  para encontrar el desfase óptimo  $\tau_{opt}$ :

$$\tau_{opt} = \arg \max_{\tau} \int_{-\infty}^{\infty} \omega_{vis}(t) \cdot \omega_{sens}(t + \tau) dt \quad (3.2)$$

Esto permitió alinear el pico de fuerza aplicado en el pedal con el ángulo de la biela correspondiente con precisión de sub-fotograma.

### 3.2.3. Modelado y simulación: física computacional

En esta etapa se predijo el comportamiento del sistema ciclista-bicicleta bajo diferentes configuraciones geométricas sin necesidad de intervención física.

#### Estimación aerodinámica ( $C_d A$ )

El sistema estimó el Área Frontal Proyectada ( $A_{proj}$ ) al utilizar una red de segmentación semántica sobre la vista lateral del ciclista. Aunque la vista lateral no capturó directamente el área frontal, se aplicaron modelos de regresión multivariable (basados en estudios de Bassett y Heil) que correlacionaron la pose sagital con el área frontal efectiva. El modelo consideró la altura del torso y el ángulo de apertura de la cadera:

$$A_{proj} \approx \alpha \cdot H_{torso} \cdot \sin(\theta_{cadera}) + \beta \cdot m_{ciclista}^{0,425} + \gamma \quad (3.3)$$

Esto permitió cuantificar el coste aerodinámico ( $P_{aero} \propto v^3 \cdot A_{proj}$ ) de cambios posturales, como bajar la altura del manillar (*Stack*).

#### Dinámica inversa plana

Al combinar la cinemática filtrada y los vectores de fuerza derivados de la potencia (se asumió una descomposición de fuerza tangencial efectiva), se resolvieron las ecuaciones de Newton-Euler para calcular los momentos netos articulares ( $M_{net}$ ) en tobillo, rodilla y cadera. Esto permitió identificar ineficiencias mecánicas, como momentos de flexión excesivos en la rodilla que no contribuyeron a la propulsión.

### 3.2.4. Optimización multi-objetivo: algoritmo genético

El núcleo decisional utilizó un algoritmo genético adaptado para resolver el Problema de Optimización Multiobjetivo. Se buscó encontrar el vector de configuración  $\mathbf{x} = [h_{sillin}, x_{sillin}, h_{manillar}, x_{manillar}]$  que satisfizo simultáneamente objetivos conflictivos.

#### Funciones objetivo

El sistema minimizó tres funciones de coste ( $J$ ):

1. Minimizar desconfort ( $J_{comfort}$ ): función de penalización cuadrática que se disparó cuando los ángulos articulares  $\theta_j$  (extensión de rodilla, flexión de hombro, etc.) salieron de los rangos fisiológicos seguros predefinidos en la



literatura médica:

$$J_{comfort}(\mathbf{x}) = \sum_{j=1}^N w_j \cdot \max(0, \theta_j(\mathbf{x}) - \theta_{max}, \theta_{min} - \theta_j(\mathbf{x}))^2 \quad (3.4)$$

2. Maximizar eficiencia biomecánica ( $J_{power}$ ): se buscó minimizar la integral del momento articular absoluto necesario para producir una potencia objetivo, lo que implicó una palanca más efectiva.
3. Minimizar resistencia aerodinámica ( $J_{aero}$ ): minimización directa del  $C_d A$  estimado en la etapa anterior.

### Configuración del algoritmo

Se empleó una población de  $N = 100$  individuos con codificación real. Se utilizó selección por torneo binario, cruzamiento simulado con probabilidad  $p_c = 0,9$  y mutación polinómica con probabilidad  $p_m = 1/L$  (donde  $L$  es el número de variables). El mecanismo de elitismo aseguró la preservación de las mejores soluciones del frente de Pareto a través de las generaciones.

#### 3.2.5. Salida y retroalimentación

La etapa final sintetizó los resultados matemáticos para el usuario final (el biomecánico o el ciclista).

- Análisis de Pareto: se presentaron soluciones categorizadas (ej. “opción confort” vs “opción aero”) extraídas del conjunto óptimo no dominado.
- Visualización de resultados: se generó una representación gráfica del frente de Pareto con las configuraciones óptimas, lo que permitió al usuario seleccionar el ajuste que mejor se adaptó a sus objetivos biomecánicos y de rendimiento.

### 3.3. Adquisición de datos

El módulo de adquisición de datos se diseñó para garantizar la integridad y la coherencia temporal de la información de entrada, un requisito crítico para la validez del análisis posterior. El sistema integró dos fuentes de información principales: la captura óptica y la telemetría de sensores.

Para la captura óptica, se estableció un protocolo de grabación estandarizado. Se utilizó una cámara de alta resolución que fue ubicada en una posición lateral estática, ortogonal al plano sagital del ciclista. Esta disposición minimizó los errores de paralaje inherentes a la proyección 2D, una limitación que se discute en el capítulo 2. El sistema se configuró para capturar video a una tasa de cuadros constante, suficiente para evitar el desenfocado de movimiento durante el pedaleo a cadencias altas.

Simultáneamente, se implementó la recolección de datos de rendimiento mediante el protocolo ANT+. Se desarrolló un *script* de escucha que se conectó a los sensores presentes en el rodillo de entrenamiento inteligente y en la bicicleta. Las variables capturadas incluyeron:

- Potencia (W).
- Cadencia (RPM).
- Velocidad virtual (km/h).
- Frecuencia cardíaca (BPM).

El desafío técnico principal en esta etapa fue la sincronización. Dado que el video y los sensores operaron con relojes independientes, se implementó un mecanismo de alineación temporal en el postprocesamiento. Se utilizó la señal de cadencia como disparador: el inicio del movimiento de las bielas que fue detectado en el video se alineó con el primer valor positivo de RPM que fue registrado por los sensores.

### 3.4. Modelado cinemático y biomecánico

Una vez que fueron extraídas las coordenadas  $(x, y)$  de los puntos anatómicos clave mediante la red neuronal, se procedió al modelado cinemático. El objetivo de este módulo fue transformar datos posicionales abstractos en métricas biomecánicas con significado clínico y deportivo.

El modelo geométrico se construyó con base en la cinemática vectorial. Se definieron vectores que representan los segmentos corporales del ciclista (fémur, tibia, torso, húmero, radio). A partir de estos vectores, se calcularon los ángulos articulares dinámicos en cada cuadro del video mediante el producto escalar. Los ángulos críticos que fueron modelados incluyeron:

- Ángulo de extensión de rodilla (KFA): calculado en el punto muerto inferior (PMI). Es el predictor principal de la altura correcta del sillín.
- Ángulo de flexión de cadera: evaluado en el punto muerto superior (PMS). Determina la restricción aerodinámica y el riesgo de pinzamiento acetabular.
- Ángulo del hombro y codo: indicadores del alcance (*reach*) y la caída (*drop*) del manillar.
- Ángulo del tobillo: analizado para evaluar la técnica de pedaleo (*ankling*).

Se aplicó un filtro de suavizado (filtro de Butterworth paso bajo) a las series temporales de los ángulos para eliminar el ruido de alta frecuencia que fue introducido por la detección cuadro a cuadro (*jitter*).

La validación de estos ángulos se realizó contra rangos de referencia bibliográficos. La tabla 3.1 detalla los parámetros biomecánicos monitoreados y sus ventanas de operación óptimas utilizadas como restricciones en el sistema.

### 3.5. Modelado del sistema

Esta sección describe el “cerebro” del sistema, que fue compuesto por la integración del modelo de detección de pose y el motor de optimización.

TABLA 3.1. Parámetros biomecánicos y rangos óptimos definidos para el modelo.

Parámetro Articular	Rango Óptimo (Grados)	Punto del Ciclo
Extensión de Rodilla (KFA)	135° – 145°	PMI
Flexión de Cadera	50° – 60°	PMS
Ángulo de Hombro	80° – 90°	Estático/Dinámico
Ángulo de Codo	150° – 160°	Estático/Dinámico
Extensión de Tobillo	90° – 100°	Promedio

### 3.5.1. Detección de pose

Para la etapa de percepción, se implementó el modelo *MediaPipe BlazePose*. Tal como se justificó en el marco teórico, este modelo ofrece una topología de 33 puntos que incluye marcadores específicos para los pies, esenciales para el análisis de ciclismo. La red neuronal procesó el flujo de video cuadro a cuadro, y se infirió la posición espacial del esqueleto del ciclista. Se configuró el modelo con parámetros de confianza de detección y seguimiento superiores a 0.5 para filtrar falsos positivos en fondos complejos.

### 3.5.2. Motor de optimización

El núcleo de la propuesta es el algoritmo de optimización multi-objetivo. Dado que la relación entre los ajustes de la bicicleta y la respuesta biomecánica es no lineal y compleja, se diseñó un Algoritmo Genético (AG). Este enfoque heurístico permite explorar eficientemente el espacio de soluciones sin necesidad de conocer la derivada de la función objetivo.

El problema de optimización se formuló de la siguiente manera:

- Genes: los parámetros ajustables de la bicicleta (altura del sillín, retroceso del sillín, longitud de la potencia, altura del manillar).
- Función de aptitud: una función compuesta que busca minimizar el error entre los ángulos medidos y los rangos óptimos, maximizar la eficiencia teórica de potencia y minimizar el área frontal (estimación aerodinámica).

El flujo del algoritmo, comenzó con una población inicial de configuraciones aleatorias (dentro de límites mecánicos viables). A través de iteraciones sucesivas de selección, cruce y mutación, el sistema convergió hacia una configuración que satisfizo las restricciones biomecánicas con el mejor compromiso de rendimiento.

En la tabla 3.2 se detallan los parámetros de configuración del algoritmo genético que fueron utilizados para asegurar la convergencia y evitar óptimos locales.

## 3.6. Reporte de recomendaciones

La etapa final del diseño corresponde a la interfaz de salida. Se desarrolló un módulo generador de reportes automatizados en formato PDF, que fue diseñado para traducir los resultados matemáticos de la optimización en instrucciones comprensibles para el usuario final.

El reporte sintetiza el análisis en tres secciones:

TABLA 3.2. Parámetros de configuración del algoritmo de optimización.

Parámetro del Algoritmo	Valor / Configuración
Tamaño de la población	100 individuos
Número de generaciones	50
Probabilidad de cruce	0.8
Probabilidad de mutación	0.2
Método de selección	Torneo
Restricciones anatómicas	Límites fisiológicos definidos

1. Diagnóstico actual: presentación visual de la postura inicial del ciclista con los ángulos medidos que fueron superpuestos sobre la imagen original, destacando en color rojo aquellos valores fuera del rango seguro.
2. Plan de ejecución: una lista detallada de las modificaciones mecánicas sugeridas. Cada instrucción especifica el componente a ajustar, la dirección del ajuste y la magnitud en milímetros (ej. "Subir sillín 5mm", "Adelantar sillín 2mm").
3. Predicción de resultados: una proyección de los nuevos ángulos biomecánicos esperados tras realizar los cambios sugeridos.

Este documento sirve como guía para que el ciclista modifique la configuración de su bicicleta. Tras la ejecución de los cambios, el sistema sugiere reiniciar el proceso de adquisición de datos para validar las mejoras, lo que cierra el ciclo de optimización continua.

## Capítulo 4

# Ensayos y resultados

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

### 4.1. Pruebas funcionales del hardware

La idea de esta sección es explicar cómo se hicieron los ensayos, qué resultados se obtuvieron y analizarlos.



## Capítulo 5

# Conclusiones

Todos los capítulos deben comenzar con un breve párrafo introductorio que indique cuál es el contenido que se encontrará al leerlo. La redacción sobre el contenido de la memoria debe hacerse en presente y todo lo referido al proyecto en pasado, siempre de modo impersonal.

### 5.1. Conclusiones generales

La idea de esta sección es resaltar cuáles son los principales aportes del trabajo realizado y cómo se podría continuar. Debe ser especialmente breve y concisa. Es buena idea usar un listado para enumerar los logros obtenidos.

En esta sección no se deben incluir ni tablas ni gráficos.

Algunas preguntas que pueden servir para completar este capítulo:

- ¿Cuál es el grado de cumplimiento de los requerimientos?
- ¿Cuán fielmente se pudo seguir la planificación original (cronograma incluido)?
- ¿Se manifestó algunos de los riesgos identificados en la planificación? ¿Fue efectivo el plan de mitigación? ¿Se debió aplicar alguna otra acción no contemplada previamente?
- Si se debieron hacer modificaciones a lo planificado ¿Cuáles fueron las causas y los efectos?
- ¿Qué técnicas resultaron útiles para el desarrollo del proyecto y cuáles no tanto?

### 5.2. Próximos pasos

Acá se indica cómo se podría continuar el trabajo más adelante.





# Bibliografía

- [1] Holliday W. Cycling Swart J. «Cycling Biomechanics Optimization-the (R) Evolution of Bicycle Fitting». En: *PubMed (Am J Sports Med)* (2019). Publicado originalmente en *Am J Sports Med*. 2020 Feb;48(2):503-513. Accedido en: <https://pubmed.ncbi.nlm.nih.gov/31834181/>. (Visitado 06-11-2025).
- [2] David Gordon Wilson y Theodor Schmidt. *Bicycling Science*. Fourth. Cambridge, Massachusetts: The MIT Press, 2020, págs. 99-100. ISBN: 9780262538404.
- [3] David Gordon Wilson y Theodor Schmidt. *Bicycling Science*. Fourth. Ver Capítulos 2 (p. 42-47) y 4 (p. 192-193) para la descripción de equipamiento especializado de laboratorio (ergómetros, túneles de viento) usado en el análisis biomecánico. Cambridge, Massachusetts: The MIT Press, 2020. ISBN: 9780262538404.
- [4] Theo R Swart J. Holliday W Fisher J. «Static versus dynamic kinematics in cyclists: A comparison of goniometer, inclinometer and 3D motion capture». En: *PubMed* (2018). Publicado originalmente en *J Sports Med Phys Fitness*. 2018 Sep;58(9):1314-1319. URL: <https://pubmed.ncbi.nlm.nih.gov/28749730/> (visitado 06-11-2025).
- [5] David Herrero. *RETÜL Bike fit technology David Herrero Biomecánica*. La fecha de acceso es 6 de noviembre de 2025, según el documento fuente. 2025. URL: <https://www.davidherrero.net/sistemas/retul-bike-fit-technology> (visitado 06-11-2025).
- [6] Vicon Motion Systems. *Vicon: Award Winning Motion Capture Systems*. Accedido: 13 de noviembre de 2025. 2025. URL: <https://www.vicon.com/>.
- [7] Li FX. Fonda B Sarabon N. «Validity and reliability of different kinematics methods used for bike fitting». En: *Journal of Sports Sciences* 32.8 (2014). Accedido en ResearchGate y PubMed. DOI: 10.1080/02640414.2013.861466. El documento fuente cita [121] y [122]., págs. 770-777. (Visitado 06-11-2025).
- [8] IA Center. *Gebiomized - IA Center*. Accedido: 13 de noviembre de 2025. 2025. URL: <https://iacenter.es/tecnologias/gebiomized/>.
- [9] Gebiomized. *gebioMized*. La fecha de acceso es 6 de noviembre de 2025. 2025. URL: <https://www.gebiomized.us/> (visitado 06-11-2025).
- [10] TrainingPeaks. *Bike Fitting, Technology, Biomechanics and the Future with Dr. Andy Pruitt*. La fecha de acceso es 6 de noviembre de 2025. 2025. URL: <https://www.trainingpeaks.com/coach-blog/bike-fitting-biomechanics-andy-pruitt/> (visitado 06-11-2025).
- [11] POC (Global EN). *CFD simulation and testing*. La fecha de acceso es 6 de noviembre de 2025. 2025. URL: <https://poc.com/en/journal/cfd-simulation-and-testing> (visitado 06-11-2025).
- [12] Elisa Digo et al. «A COMPUTATIONAL METHODOLOGY FOR RECUMBENT BICYCLE FITTING TO OPTIMIZE AERODYNAMIC EFFICIENCY WHILE ENSURING RIDER COMFORT». En: *International Journal of Mechanics and Control* 25 (jun. de 2024), págs. 105-114. DOI: [10.69076/jomac.2024.0015](https://doi.org/10.69076/jomac.2024.0015).

- [13] T. van Druenen. *Optimizing aerodynamic performance in cycling - TUE Research portal*. Tesis de Eindhoven University of Technology. La fecha de acceso es 6 de noviembre de 2025. 2024. URL: [https://research.tue.nl/files/340281097/20241016\\_Druenen\\_van\\_hf.pdf](https://research.tue.nl/files/340281097/20241016_Druenen_van_hf.pdf) (visitado 06-11-2025).
- [14] Bicycle Retailer. *AiRO Launches World's First AI-Powered, CFD-Modelled Aero Bike Fit Platform*. La fecha de acceso es 6 de noviembre de 2025. 2025. URL: <https://www.bicycleretailer.com/announcements/2025/08/18/airo-launches-world-s-first-ai-powered-cfd-modelled-aero-bike-fit-platform> (visitado 06-11-2025).
- [15] Notio. *Notio - Free the Speed – NotioArgon18support*. La fecha de acceso es 6 de noviembre de 2025. 2025. URL: <https://notio.ai/> (visitado 06-11-2025).
- [16] Global Triathlon Network (GTN). *Power Or More Aero? | GTN Experiment With The Notio Aerodynamics*. La fecha de acceso es 6 de noviembre de 2025. 2025. URL: [https://www.youtube.com/watch?v=\\_CxZZuT7ykk](https://www.youtube.com/watch?v=_CxZZuT7ykk) (visitado 06-11-2025).
- [17] MyVeloFit. *Online Bike Fit - MyVeloFit*. La fecha de acceso es 6 de noviembre de 2025. 2025. URL: <https://www.myvelofit.com/bike-fitting/> (visitado 06-11-2025).
- [18] Bike Fast Fit. *Bike Fast Fit - Online Bike Fitting*. La fecha de acceso es 6 de noviembre de 2025. 2025. URL: <https://bikefastfit.com/> (visitado 06-11-2025).
- [19] et al. Priego-Quesada JI. «Bicycle Set-Up Dimensions and Cycling Kinematics: A Consensus Statement Using Delphi Methodology». En: *PubMed Central (Sports Med Open)* (2024). URL: <https://pmc.ncbi.nlm.nih.gov/articles/PMC11561003/> (visitado 06-11-2025).
- [20] Rodrigo Iván Goñi. *Plan de proyecto del Trabajo Final: Optimización biomecánica del ciclismo asistida por inteligencia artificial (RG\_v5)*. 2025.
- [21] Kaiming He et al. «Mask R-CNN». En: *arXiv preprint arXiv:1703.06870* (2017). URL: <https://arxiv.org/abs/1703.06870>.
- [22] Camillo Lugaresi et al. «MediaPipe: A Framework for Building Perception Pipelines». En: *arXiv preprint arXiv:1906.08172* (2019). URL: <https://arxiv.org/abs/1906.08172>.
- [23] Keiron O'Shea y Ryan Nash. «An Introduction to Convolutional Neural Networks». En: *arXiv preprint arXiv:1511.08458* (2015). Fecha de acceso: noviembre 11, 2025. DOI: [10.48550/arXiv.1511.08458](https://doi.org/10.48550/arXiv.1511.08458). URL: <https://arxiv.org/abs/1511.08458>.
- [24] Adrian Bulat y Georgios Tzimiropoulos. «Human pose estimation via Convolutional Part Heatmap Regression». En: *arXiv preprint arXiv:1609.01743* (2016). Fecha de acceso: noviembre 10, 2025. URL: <https://ar5iv.labs.arxiv.org/html/1609.01743>.
- [25] Enrico Callaris. *Vanishing Point Detection with CNN-Based Heatmap Regression*. Medium. Fecha de acceso: noviembre 10, 2025. 2019. URL: <https://medium.com/@callaris.enrico/detecting-vanishing-point-through-cnn-based-heatmap-regression-4702991e3f5d>.
- [26] *How to parse the heatmap output for the pose estimation tfLite model?* Stack Overflow. Pregunta de febrero 18, 2020. Fecha de acceso: noviembre 10, 2025. 2020. URL: <https://stackoverflow.com/questions/60032705/how-to-parse-the-heatmap-output-for-the-pose-estimation-tflite-model>.
- [27] LearnOpenCV. *YOLOv7 Pose vs MediaPipe in Human Pose Estimation*. Fecha de acceso: noviembre 10, 2025. URL: <https://learnopencv.com/yolov7-pose-vs-mediapipe-in-human-pose-estimation/>.

- [28] Google AI Edge. *Pose landmark detection guide*. Fecha de acceso: noviembre 10, 2025. URL: [https://ai.google.dev/edge/mediapipe/solutions/vision/pose\\_landmarker](https://ai.google.dev/edge/mediapipe/solutions/vision/pose_landmarker).
- [29] LearnOpenCV. *Human Pose Estimation using Keypoint RCNN in PyTorch*. Fecha de acceso: noviembre 10, 2025. URL: <https://learnopencv.com/human-pose-estimation-using-keypoint-rcnn-in-pytorch/>.
- [30] Valentin Bazarevsky, Ivan Grishchenko y et al. «BlazePose GHUM Holistic: Real-time 3D Human Landmarks and Pose Estimation». En: *arXiv preprint arXiv:2206.11678* (2022). Fecha de acceso: noviembre 10, 2025. URL: <https://arxiv.labs.arxiv.org/html/2206.11678>.
- [31] David E. Goldberg. *Genetic Algorithms in Search, Optimization and Machine Learning*. Reading, Massachusetts: Addison-Wesley Publishing Company, Inc., 1989. ISBN: 0-201-15767-5.
- [32] UPV. *Selección de individuos en Algoritmos Genéticos*. Fecha de acceso: noviembre 10, 2025. URL: <https://www.youtube.com/watch?v=LPsm1RT1DqQ> (visitado 10-11-2025).
- [33] Wikipedia. *Selección por torneos - Wikipedia, la enciclopedia libre*. Fecha de acceso: noviembre 10, 2025. URL: [https://es.wikipedia.org/wiki/Selecci%C3%B3n\\_por\\_torneos](https://es.wikipedia.org/wiki/Selecci%C3%B3n_por_torneos).
- [34] IBM. *Visión general de la ayuda de CRISP-DM*. 2024.
- [35] ANT+ Alliance. *The ANT+ Protocol: Technical Specification and Developer Zone*. 2024. URL: <https://www.thisisant.com/developer/ant-plus/>.
- [36] Carles Gómez, Joaquim Oller y Josep Paradells. «Overview and Evaluation of Bluetooth Low Energy: An Emerging Low-Power Wireless Technology». En: *Sensors* 12.9 (2012), págs. 11734-11753. DOI: [10.3390/s120911734](https://doi.org/10.3390/s120911734). URL: <https://www.mdpi.com/1424-8220/12/9/11734>.
- [37] Wikipedia contributors. *Quinto hueso metatarsiano*. URL: [https://es.wikipedia.org/wiki/Quinto\\_hueso\\_metatarsiano](https://es.wikipedia.org/wiki/Quinto_hueso_metatarsiano) (visitado 20-11-2025).
- [38] GoldenCheetah Project. *GoldenCheetah: Performance Software for Cyclists, Runners and Triathletes*. 2025. URL: <https://www.goldencheetah.org/> (visitado 20-05-2025).